WTIS V4.1

WTIS Report: 멀티모달 VLM 통신사 적용

2026-03-12

Executive Summary

Conditional Go (148/200) — 멀티모달 VLM은 시장매력도(36/40)와 고객가치(33/40)가 강력하나, 자사 특허 부재(4/10)와 경쟁우위 불확실(24/40)이 주요 감점 요인이다. **Build-First with Strategic Borrow** 전략을 권고하며, 3개월 PoC에서 한국어 CC-OCR 75점 이상·FCR 25% 이상·VLM 전문인력 3명 확보를 달성하면 Go(160+) 전환 가능하다. 오픈소스 VLM(Qwen2.5-VL 7B, DocVQA 96.4%)의 성숙과 온프레미스 TCO 우위(연 $18K~216K 절감), 프라이버시 규제 대응력이 추진 근거이며, SKT A.X K1 이미지 멀티모달(2026H1) 대비 B2B 문서 AI·MEC 엣지 차별화로 경쟁 포지셔닝한다.

❶ 시장 분석

구분	시장	규모	CAGR	출처
TAM	글로벌 멀티모달 AI	2026 $3.4~3.9B → 2030 $11~23B	32~38%	D-01(#ref-d-01), D-02(#ref-d-02)
TAM	글로벌 IDP(문서 AI)	2025 $3.2B → 2034 $43.9B	33.7%	DA-05(#ref-da-05), DA-06(#ref-da-06)
TAM	글로벌 영상 AI	2025 $32B → 2030 $133B	33%	D-10(#ref-d-10)
SAM	통신 AI	2025 $2.06B → 2034 $14.86B	22%	G-03
SAM	AICC (컨택센터 AI)	2025 $4.4B → 2030 $14.6B	~27%	복수 시장 조사 추정
SOM	국내 통신사 VLM 적용	연간 $5~15M (초기 3년)	-	자체 추정 [추정, 근거부족]

< TAM/SAM/SOM >

세부 지표	점수	근거
TAM/SAM/SOM	9/10	TAM $3.4~23B(멀티모달)+$43.9B(IDP). SOM 연 $5~15M은 국내 한정이나 확장 가능
CAGR	10/10	모든 관련 시장 25% 이상 고성장 — 최고점 D-01(#ref-d-01)
시장 타이밍	9/10	글로벌 통신사 모두 파일럿 단계 → 선점 윈도우 존재 CS-03(#ref-cs-03)
규제/정책	8/10	개인정보보호위원회 안내서(2025.8)로 법적 근거 명확 CS-06(#ref-cs-06)

< 시장매력도 채점 근거 (36/40) >

항목	상용 API (GPT-4o)	온프레미스 (Qwen 7B)
월 API/추론 비용	$8,500~25,000	$0 (자체 GPU)
GPU 인프라	불필요	A100 80GB × 2: $30,000~60,000 (CapEx)
월 운영 비용	API 비용만	$2,000~4,500 (전력·유지·엔지니어링)
연간 TCO	$102,000~300,000	$54,000~84,000 (2년차~)
연간 절감	—	**$18K~246K** (범위에 따라 상이)
프라이버시	국외 이전 동의 필요	온프레미스 처리, 동의 불요

< 비용 분석 >

손익분기점: 월 ~9,500만 토큰(일 315만 토큰) 이상에서 온프레미스 유리 CS-05(#ref-cs-05)

❷ 기술 성숙도 분석

TRL 4사분면 맵

```
파괴적 혁신도 (높음)
      |
      |  [잠재 파괴자]                [전략적 기회]
      |  음성+시각 통합 에이전트       엣지 VLM 플랫폼
      |  (TRL 4, 파괴도 9)             (TRL 6, 파괴도 8)
      |  자율 네트워크 AI-RAN
      |  (TRL 4, 파괴도 8)
      |
      |  [기초 연구]                  [즉시 상용화]
      |                                ★고객서비스 비전 AI (TRL 6-7)
      |                                ★B2B 문서 AI (TRL 7-8)
      |                                ★네트워크 비전 모니터링 (TRL 5-6)
      |
      └──────────────────────────────────────────────→ 기술 성숙도 (높음)
```

적용 분야	TRL	근거	상용화까지
핵심 VLM 엔진	9	GPT-4o, Qwen2.5-VL 모두 프로덕션 배포 중	즉시
고객서비스 AICC 통합	6~7	VLM 준비, AICC 연동 표준 API 부재 CS-01(#ref-cs-01)	3~6개월
B2B 문서 AI	7~8	PaddleOCR-VL SOTA, 업스테이지 상용 납품 중 DA-01(#ref-da-01)	3개월
MEC 엣지 배포	6~7	Moondream 2B 실동작, MBQ 양자화 검증 EV-01(#ref-ev-01)	6~9개월
실시간 영상 VLM	5~6	StreamingVLM 8 FPS/H100 EV-02(#ref-ev-02)	9~12개월

< TRL 상세 >

기준	판정	근거
Specific	PASS	FCR 30~50%, 문서 수작업 60% 단축 — 정량적 목표
Measurable	PASS	FCR은 기존 AICC에서 측정 중, 문서 처리 시간은 RPA 로그로 추적
Achievable	CONDITIONAL	Qwen2.5-VL DocVQA 96.4%이나 한국어 69.1점 → 75점 파인튜닝 필요 P-01
Relevant	PASS	통신사 97% AI 도입 검토, 산업 방향 일치 G-03
Time-bound	PASS	SKT 2026H1 → 3개월 PoC로 동시 진입 가능 CS-03(#ref-cs-03)

< SMART Test >

용도	모델	파라미터	VRAM (INT4)	근거
고객 서비스 (서버)	Qwen2.5-VL 7B	7B	~5GB	DocVQA 96.4%, 한국어 69.1점 P-03
문서 AI (서버)	PaddleOCR-VL 1.5	0.9B	<2GB	OmniDocBench 94.5 SOTA DA-01(#ref-da-01)
CCTV 분석 (서버)	StreamingVLM	7B+	~17GB	무한 스트림 안정 처리 EV-02(#ref-ev-02)
엣지 경량	Moondream 2B	2B	2.45GB	RTX 3090급 엣지 서버 EV-06(#ref-ev-06)

< 모델 선정 가이드 >

③ 경쟁 환경

항목	자사	SKT	KT	Deutsche Telekom	Verizon
멀티모달 전략	미발표 (평가 중)	A.X K1 이미지 2026H1	에이전틱 패브릭	Sprinklr CCaaS	Project 624
자체 모델	없음	A.X K1 500B	믿:음 K	없음	없음
이미지 VLM FCR	없음	없음	없음	없음	없음
문서 AI	없음	예정	믿:음 K 문서 인식	없음	없음
MEC AI	인프라 보유	엣지 전략	MS Azure 파트너	없음	없음

< 경쟁사 비교표 >

Gap 영역	현재	목표	해소 방안	기간
자체 VLM 모델	없음	한국어 특화 7B	오픈소스 파인튜닝	3개월
한국어 OCR	0점	75점+ (CC-OCR)	통신 도메인 데이터셋 + 파인튜닝	3개월
VLM 전문 인력	부족	3~5명	채용 + 업스테이지 협력	3~6개월
특허 포트폴리오	0건	5건+	PoC 과정에서 출원	6~12개월

< Gap Analysis >

기업 발언 (직접 인용)

***E-01 (Deutsche Telekom)**: "Our agents are the face of our brand. We want to use AI-powered solutions to help them — but never to replace them." — Löwemann (DT 임원) CS-01(#ref-cs-01)*

***E-02 (Verizon)**: "Verizon can accurately predict the purpose of customer calls 80% of the time" — Verizon 공식 발표 CS-02(#ref-cs-02)*

***E-03 (SKT)**: "AI Contact Center를 금융기관 등에 확장하고, Vision AI + Language AI + Big Data AI를 통합하는 멀티LLM 전략을 추진한다." — SKT CEO 정재훈, MWC 2026 CS-03(#ref-cs-03)*

④ 전략 권고

구성 요소	추천	근거
VLM 핵심 모델	**Build**	온프레미스 TCO 우위 + 프라이버시 규제 대응 CS-05(#ref-cs-05), CS-06(#ref-cs-06)
한국어 학습 데이터	**Build + Borrow**	통신 도메인 자체 구축 + 일반 한국어 협력
AICC 통합	**Build**	기존 AICC 아키텍처 내부 지식 활용
문서 AI 엔진	**Borrow → Build**	초기 업스테이지 API → 점진적 내재화 DA-04(#ref-da-04)
GPU 인프라	**Build**	일 10만 건+ 시 온프레미스 TCO 우위
MEC 배포	**Build + Borrow**	자사 MEC + NVIDIA TensorRT EV-06(#ref-ev-06)

< 3B 의사결정 경로 >

Phase	기간	목표	투자	Go/No-Go
Phase 1: PoC	2026 Q2 (3M)	한국어 75점+, 모뎀 LED 진단 PoC, FCR 25%+	$150~200K	CC-OCR 75+, FCR 25%+
Phase 2: 상용화	2026 Q3~Q4 (6M)	AICC 통합, 문서 AI B2B 1호	$500K~1M	FCR 30%, B2B 3건+
Phase 3: 확장	2027 H1 (6M)	MEC 엣지, B2B 10사+, 네트워크 모니터링	$1~2M	B2B 매출 $1M+

< Phase별 로드맵 >

#	평가 항목	pain point 심각도 (10)	제공 가치 명확성 (10)	대체제 대비 우위 (10)	고객 수용성 (10)	소계 (40)
1	고객가치	9	8	8	8	**33**

< 200점 채점표 >

#	평가 항목	TAM/SAM/SOM (10)	CAGR (10)	시장 타이밍 (10)	규제/정책 (10)	소계 (40)
2	시장매력도	9	10	9	8	**36**

#	평가 항목	TRL 수준 (10)	특허 포트폴리오 (10)	기술 장벽 (10)	표준/인증 (10)	소계 (40)
3	기술경쟁력	8	4	8	8	**28**

#	평가 항목	시장 포지션 (10)	차별화 지속성 (10)	경쟁사 대응력 (10)	생태계/파트너 (10)	소계 (40)
4	경쟁우위	6	6	5	7	**24**

#	평가 항목	내부 역량 (10)	투자 대비 ROI (10)	일정 현실성 (10)	리스크 관리 (10)	소계 (40)
5	실행가능성	6	7	7	7	**27**

| | **총점** | | | | **148/200** |

종합 판정: Conditional Go (148/200)

Go 전환 조건:

- [ ] Phase 1 PoC: 한국어 CC-OCR **75점 이상** 달성 (현재 69.1점)
- [ ] Phase 1 PoC: 고객 서비스 **FCR 25% 이상** 달성
- [ ] VLM 전문인력 **3명 이상** 확보 (채용 또는 협력)

3개 조건 충족 시 기술경쟁력(+4~6점)·실행가능성(+3~5점) 개선으로 155~159점 도달. B2B 1호 계약 추가 확보 시 경쟁우위(+2~3점)으로 **Go(160+) 달성 가능**.

#	리스크	영향	확률	완화 방안
R1	한국어 파인튜닝 목표(75점) 미달	크리티컬	중	다중 모델 후보 병행, 업스테이지 협력
R2	SKT K1 이미지 멀티모달 조기 출시	높음	중	B2B 문서 AI·MEC 엣지 차별화 집중
R3	GPU 공급 부족/가격 상승	중간	중	클라우드 하이브리드, INT4 양자화
R4	개인정보 규제 강화	중간	낮	온프레미스 배포로 선제 대응, DPIA 조기 수행
R5	PoC 기간 내 FCR 목표 미달	높음	중	신뢰도 게이팅(0.85), 인간-AI 협업

< 리스크 레지스터 >

Next Action

1. **[Week 1~2]** ML엔지니어 채용 공고 + 업스테이지 기술 미팅
2. **[Week 2~4]** Qwen2.5-VL 7B 온프레미스 환경 구축 (A100 × 2, vLLM)
3. **[Week 3~6]** 통신 장비 이미지 데이터셋 구축 (모뎀 LED, 셋톱박스, 공유기)
4. **[Week 4~8]** 한국어 파인튜닝 → CC-OCR 재측정
5. **[Week 6~12]** AICC 연동 PoC + 내부 시범 서비스 (상담사 200명)
6. **[Week 4]** DPIA(개인정보 영향평가) 착수

5 교차검증 결과

#	유형	심각도	내용	처리
I-01	수치 오류	높음	TCO 절감 "$48~216K" → 실제 범위 "$18~246K"	**해소** — final에서 정확한 범위($18K~246K) 사용
I-02	논리 모순	높음	"155~159점 → Go 경계 도달" — Go는 160+	**해소** — "Go(160+) 달성 가능"으로 수정, B2B 계약 추가 점수 명시
I-03	시간 불일치	중간	"6~12개월 선점" vs "0~6개월"	**해소** — "동시 진입 또는 B2B/MEC 차별화" 표현으로 통일
I-04	출처 누락	중간	AICC SAM $4.4B → $14.6B 출처 없음	**잔존** — "복수 시장 조사 추정"으로 명시, 신뢰도 하향
I-05	중복 출처	낮음	D-05=G-03, D-04=EV-04, CS-04=P-01	**잔존** — References에서 정리 (별도 ID 유지, 중복 주석)

< Validator 판정: PARTIAL >

References

#	출처	URL	유형	날짜
D-01	GM Insights — Multimodal AI Market 2025-2034	링크	report	2026
D-02	Grand View Research — Multimodal AI Market 2030	링크	report	2026
D-03	Qwen3-VL Technical Report	링크	paper	2025
D-04	Nature Communications — MiniCPM-V (= EV-04)	링크	paper	2025
D-05	NVIDIA — AI in Telecom Survey (= G-03)	링크	report	2026
D-06	Huawei — Agentic Internet MWC 2026	링크	news	2026-03
D-07	SKT 뉴스룸 — A.X K1 멀티모달 확장	링크	IR	2026
D-08	ZDNet Korea — SKT 멀티모달 계획	링크	news	2026-01
D-09	Google Patents — Vision-Language Pretraining	링크	patent	2024
D-10	Voxel51 — Visual AI Video 2026	링크	report	2026

< Discover 리포트 (D-xx) >

#	출처	URL	유형	날짜
CS-01	Deutsche Telekom × Sprinklr CCaaS	링크	case	2025
CS-02	Verizon Project 624 AI Overhaul	링크	news	2025
CS-03	SKT CEO MWC 2026 AI Native Strategy	링크	IR	2026-03
CS-04	CC-OCR Benchmark (= P-01)	링크	paper	2024-12
CS-05	On-Premise LLM Break-Even Analysis	링크	paper	2025-09
CS-06	개인정보보호위원회 생성형 AI 안내서	링크	gov	2025-08

< 고객 서비스 VLM (CS-xx) >

#	출처	URL	유형	날짜
EV-01	MBQ: VLM 양자화 (CVPR 2025)	링크	paper	2025
EV-02	StreamingVLM (MIT Han Lab)	링크	paper	2025-10
EV-03	VideoScan	링크	paper	2025-03
EV-04	MiniCPM-V 2.6 (Nature Communications)	링크	paper	2025
EV-05	Columbia Distributed VLMs	링크	paper	2025-04
EV-06	NVIDIA Jetson Edge AI Guide	링크	doc	2025

< 엣지 VLM (EV-xx) >

#	출처	URL	유형	날짜
DA-01	PaddleOCR-VL 1.5	링크	paper	2026-01
DA-02	OmniDocBench (CVPR 2025)	링크	repo	2025
DA-03	Mistral OCR 3	링크	product	2026
DA-04	Upstage $45M Series B	링크	news	2025-08
DA-05	Grand View Research — IDP Market 2030	링크	report	2025
DA-06	Precedence Research — IDP Market $43.9B	링크	report	2025
DA-07	KT MWC 2026 에이전틱 패브릭	링크	news	2026-03

< 문서 AI B2B (DA-xx) >

#	출처	URL	유형	날짜
P-01	CC-OCR: Comprehensive OCR Benchmark	링크	paper	2024-12
P-03	Qwen2.5-VL Technical Report	링크	paper	2025-02

< 학술 논문 (P-xx) >

#	출처	URL	유형	날짜
G-03	NVIDIA — AI in Telecom Market	링크	report	2026

< 기타 (G-xx) >