WTIS V4.1

Research: 멀티모달 VLM — 통신사 적용 심층 분석

2026-03-12 | 출처 1건

연구 질문

> *Discover에서 도출한 즉시착수 3건(고객 서비스 비전 AI, B2B 문서 AI, 네트워크 비전 모니터링)의 기술적 실현 가능성, 비용 구조, 경쟁 상황을 심층 검증한다.*

핵심 발견

1. 글로벌 통신사의 이미지 VLM 고객 서비스는 아직 파일럿 단계

Deutsche Telekom(Sprinklr CCaaS, 41,000 상담원), Verizon(Project 624, AI 이탈방지 10만 명), SKT(A.X K1 이미지 멀티모달 2026H1) 모두 텍스트 AI 중심이며, **이미지 기반 VLM 자동 진단의 공개 FCR(1차 해결율) 수치는 아직 없다.** 즉 선점 기회가 열려 있다.

2. 온프레미스 VLM은 일 10만 건 이상에서 API 대비 TCO 우위

- GPT-4o 이미지 처리: 월 $8,500~25,000 (일 10만 건)
- 온프레미스 A100: 월 $2,000~4,500 (전력·유지 포함)
- **손익분기**: 월 ~9,500만 토큰(일 315만 토큰) 이상에서 온프레미스 유리
- 초기 GPU CapEx $15K~60K + 엔지니어링 비용 고려 필요

3. 한국어 VLM 성능은 상용 API 대비 11점 격차

CC-OCR 벤치마크 한국어: Gemini-1.5-Pro **80.0점** > GPT-4o 74.2점 > Qwen-VL-Max **69.1점**(온프레미스 최강). 라틴계 언어 대비 전반적으로 낮으며, 한국어 특화 파인튜닝이 차별화 포인트.

4. 엣지 VLM 배포는 INT4 양자화로 현실화

MBQ(CVPR 2025)로 W4A8 정확도 손실 1.1% 이내. Moondream 2B INT4는 2.45GB VRAM에서 184 tokens/s 달성. MEC 100ms 목표는 비전 인코더-엣지 / LLM 디코더-클라우드 분리 아키텍처로 달성 가능.

5. OCR-free 문서 AI는 PaddleOCR-VL이 SOTA

PaddleOCR-VL 1.5(0.9B): OmniDocBench 94.5점 SOTA, 109개 언어(한국어 포함), 오픈소스. Mistral OCR 3: $2/1,000페이지. 한국어 특화 1위는 **업스테이지**($45M 투자, 삼성·보험사 납품).

6. 실시간 영상 처리는 H100에서 8 FPS 수준

StreamingVLM(MIT): H100 1장에서 8 FPS, 3시간+ 무한 스트림 처리. VideoScan: RTX 4090에서 6 FPS. CCTV 전수 분석(25 FPS)은 불가 → **경량 비전 모델 1차 필터링 + VLM 이벤트 분석** 캐스케이드가 현실적.

기술 아키텍처 비교

고객 서비스 VLM 파이프라인

```
고객 사진 전송 → 전처리(EXIF 제거, 마스킹, 리사이즈)
              → VLM 추론(Qwen2.5-VL 7B, vLLM)
              → 신뢰도 게이팅(≥0.85 자동응답, <0.85 에스컬레이션)
              → AICC 연동(CRM 티켓 생성)
```

MEC 엣지 배포 아키텍처

```
[엣지 단말] → [MEC 노드: 비전 인코더 + 경량 추론]
                        ↓ (복잡 쿼리만)
              [클라우드: 대형 VLM 디코더]
```

- MEC 자체 지연: 20ms 이하 → 모델 추론 예산 80ms
- 5G 네트워크 슬라이싱으로 AI 추론 우선순위 보장 가능

모델 선정 가이드

용도	모델	파라미터	VRAM (INT4)	추론 속도	근거
고객 서비스 (서버)	Qwen2.5-VL 7B	7B	~5GB	~21 req/s (A100)	DocVQA 96.4%, 한국어 69.1점
문서 AI (서버)	PaddleOCR-VL 1.5	0.9B	<2GB	고속	OmniDocBench 94.5 SOTA
CCTV 분석 (서버)	StreamingVLM	7B+	~17GB	8 FPS (H100)	무한 스트림 안정 처리
엣지 경량	Moondream 2B	2B	2.45GB	184 tok/s	RTX 3090급 엣지 서버
모바일/IoT	SmolVLM-256M	0.26B	~0.8GB	80 tok/s	브라우저 실행 가능

< 용도별 최적 모델 >

방법	메모리 절감	정확도 유지	최적 환경
AWQ INT4	~75%	95%	저지연 엣지 GPU
MBQ W4A8	~75%	98.9% (VLM 특화)	VLM 전용 배포
GGUF Q4_K_M	~75%	92%	CPU+GPU 혼합 엣지
NVFP4	~75%	INT4보다 우수	H100/A100 MEC

< 양자화 방법 선정 >

프레임워크	최적 용도	처리량
vLLM	멀티유저 MEC 서버	120~160 req/s
TensorRT Edge-LLM	NVIDIA Jetson 엣지	최고 성능
llama.cpp	CPU/GPU 혼합 엣지	단일 스트림
MLC-LLM	iOS/Android/브라우저	크로스플랫폼

< 추론 프레임워크 선정 >

국내 경쟁 환경

통신사	멀티모달 전략	강점	약점
SKT	A.X K1 → 이미지(2026H1) → 음성·영상 → 1000B	자체 모델, MAU 1,000만	멀티모달 아직 미출시
KT	믿:음 K 문서 인식 + 에이전틱 패브릭	B2B 실증 경험, MS 파트너십	VLM 독립 서비스 미발표

< 통신사 >

플레이어	포지션	한국어	비고
업스테이지	한국어 문서 AI 1위	최강	$45M 투자, 삼성·보험사
NAVER CLOVA OCR	네이버 클라우드 생태계	강함	영수증·명함 특화
PaddleOCR-VL	글로벌 SOTA	지원(109개 언어)	한국어 특화 부족
Mistral OCR 3	가격 경쟁력	라틴 대비 열위	$2/1,000페이지

< 문서 AI 플레이어 >

비용 분석 상세

항목	상용 API (GPT-4o)	온프레미스 (Qwen 7B)
월 API/추론 비용	$8,500~25,000	$0 (자체 GPU)
GPU 인프라	불필요	A100 80GB × 2: $30,000~60,000 (CapEx)
월 운영 비용	API 비용만	$2,000~4,500 (전력·유지·엔지니어링)
연간 TCO	$102,000~300,000	$54,000~84,000 (2년차~)
프라이버시	국외 이전 동의 필요	온프레미스 처리, 동의 불요
한국어 성능	74.2~80.0점	69.1점 (11점 격차)

< 고객 서비스 VLM — 일 10만 건 시나리오 >

판단: 일 10만 건 이상이면 온프레미스가 비용·프라이버시 모두 우위. 한국어 성능 격차(11점)는 파인튜닝으로 축소 가능.

프라이버시/규제

개인정보보호위원회 2025.8. 생성형 AI 안내서 기준:

- 고객 제출 이미지: **서비스 계약 수행 목적**으로 처리 가능 (동의 재취득 불요)
- AI 모델 **학습 재사용**: 별도 동의 또는 가명처리 필수
- **해외 API**(GPT-4V, Gemini): 국외 이전 고지·동의 필요 → 온프레미스 우위
- 원본 이미지 즉시 삭제(90일 이내) 권장
- 전처리 필수: EXIF 메타데이터 제거, 얼굴/배경 마스킹

신뢰도 평가

높은 확신

- **엣지 VLM 하드웨어 요구사항**: Nature Communications 논문 + NVIDIA 공식 벤치마크 + 다중 오픈소스 실측 데이터
- **양자화 성능**: CVPR 2025 MBQ 논문 — 피어리뷰 완료
- **비용 분석**: arXiv 손익분기 분석 + 복수 벤더 가격표 교차 검증
- **한국어 OCR 벤치마크**: CC-OCR 벤치마크(arXiv) — 16개 모델 체계적 비교
- **개인정보보호 규제**: 개인정보보호위원회 공식 안내서 (2025.8)

추가 검증 필요

- **통신사 이미지 VLM FCR 수치**: 어떤 통신사도 공식 발표 없음 → 자체 파일럿 필요
- **한국어 파인튜닝 효과**: Qwen 69.1 → 목표 75+ 달성 가능 여부 실험 필요
- **MEC 실배포 지연시간**: 이론 100ms 가능하나 실환경(네트워크 변동, 동시 접속) 검증 필요
- **KT 멀티모달 전략**: 공개 정보 부족, 에이전틱 패브릭과의 통합 방향 추가 확인

액션 아이템

- [ ] **고객 서비스 VLM 파일럿**: Qwen2.5-VL 7B + vLLM으로 모뎀 LED 진단 PoC 구축 → FCR 측정
- [ ] **한국어 파인튜닝**: Qwen2.5-VL 7B에 통신 장비 이미지 + 한국어 라벨 데이터셋으로 파인튜닝 → CC-OCR 75+ 목표
- [ ] **문서 AI PoC**: PaddleOCR-VL 1.5로 통신사 내부 계약서/청구서 자동 처리 파일럿
- [ ] **MEC 배포 테스트**: Moondream 2B INT4를 MEC 노드에 배포, 100ms 이하 지연시간 실측
- [ ] **CCTV 캐스케이드 설계**: YOLO 1차 필터링 + StreamingVLM 이벤트 분석 아키텍처 PoC
- [ ] **개인정보 영향평가**: 고객 이미지 처리에 대한 DPIA(Data Protection Impact Assessment) 수행

참고 자료

#	출처명	URL	유형	날짜
CS-01	Deutsche Telekom × Sprinklr CCaaS	링크	case	2025
CS-02	Verizon Project 624 AI Overhaul	링크	news	2025
CS-03	SKT CEO MWC 2026 AI Native Strategy	링크	IR	2026-03
CS-04	CC-OCR Benchmark (한국어 OCR 비교)	링크	paper	2024-12
CS-05	On-Premise LLM Break-Even Analysis	링크	paper	2025-09
CS-06	개인정보보호위원회 생성형 AI 안내서	링크	gov	2025-08

< 고객 서비스 VLM >

#	출처명	URL	유형	날짜
EV-01	MBQ: VLM 양자화 (CVPR 2025)	링크	paper	2025
EV-02	StreamingVLM (MIT Han Lab)	링크	paper	2025-10
EV-03	VideoScan	링크	paper	2025-03
EV-04	MiniCPM-V 2.6 (Nature Communications)	링크	paper	2025
EV-05	Columbia Distributed VLMs	링크	paper	2025-04
EV-06	NVIDIA Jetson Edge AI Guide	링크	doc	2025
EV-07	SmolVLM (HuggingFace)	링크	blog	2025
EV-08	NVIDIA TensorRT Edge-LLM	링크	doc	2025

< 엣지 VLM 배포 >

#	출처명	URL	유형	날짜
DA-01	PaddleOCR-VL 1.5	링크	paper	2026-01
DA-02	OmniDocBench (CVPR 2025)	링크	repo	2025
DA-03	Mistral OCR 3	링크	product	2026
DA-04	Upstage $45M Series B	링크	news	2025-08
DA-05	Grand View Research — IDP Market 2030	링크	report	2025
DA-06	Precedence Research — IDP Market $43.9B	링크	report	2025
DA-07	KT MWC 2026 에이전틱 패브릭	링크	news	2026-03
DA-08	NAVER CLOVA OCR	링크	product	2026

< 문서 AI B2B >