WTIS V4.1

WTIS Report: OnDevice AI — sLM 경량화 & 실시간 화자 분할

2026-03-10

경영진 요약

재검토 (107/200) — 이전 분석(2026-03-03 Conditional Go 120/200) 대비 13점 하락. 기술 성숙도(TRL 7~8)는 확인되었으나, B2C 시장 축소 위협이 극적으로 확대되어 사업 타당성 재설계가 필수적이다.

3가지 핵심 변화:

1. **기술은 준비됐다** — Snapdragon 8 Elite Gen 5에서 3B 모델 220 tok/s 달성 G-03, Picovoice Falcon/SpeakerKit 온디바이스 화자분할 상용화 G-10 → 실시간 통화 추론 기술적 장벽 소멸.
2. **시장은 축소 중** — Samsung S26 Gauss sLM 무료 내장(Feb 2026) E-01 + Apple SpeechAnalyzer 무료 API(WWDC25) E-02 → B2C 유료 서비스 진입 창 급속 축소.
3. **동료도 모델 미검증** — SKT 에이닷 유료화 2026.03 연기, CTO "기술 성능이 유료 수준 미달" E-04 → 시장 WTP 자체 미검증.

전략: Borrow(화자분할 SDK) + Build(한국어 특화 파인튜닝) + **B2B 프라이버시 포지셔닝으로 선회**. B2C 유료 서비스는 WTP 검증 완료까지 연기 권고. 신뢰도: Medium (배터리 소모, 한국어 DER, WTP 데이터 부재).

이전 분석 대비 변화

> *이전 분석: `2026-03-03_secure-ai-v2/final.md` (2026-03-03)*

항목	이전 (2026-03-03)	현재 (2026-03-10)	변화
핵심 판정	Conditional Go (120/200)	**재검토 (107/200)**	↓ -13점
신뢰도	Medium	Medium	→
주요 위험	Samsung S26 무료 탐지	B2C 유료 창 전면 축소 + WTP 미검증	↓ 악화
기술 성숙도	commodity화 판정 (TRL 7~8)	TRL 7~8 재확인, 220 tok/s 돌파	→ 기술 진화 확인
전략	Borrow(PQC) + Build(OnDevice)	**Borrow(SDK) + Build(한국어) + B2B 선회**	↓ 전략 전환

변화 주요 원인:

- Samsung S26(Feb 2026) Gauss 3~7B sLM + 보이스피싱 탐지 **무료** 내장 확정 E-01 — B2C 차별화 축 완전 소멸
- SKT 에이닷 유료화 연기(2026.03) — 동종 선도사도 WTP 미검증 E-04
- Qualcomm 220 tok/s 달성으로 기술 장벽 소멸 — 누구나 접근 가능한 commodity 확정 G-03
- Picovoice Falcon/Argmax SpeakerKit 상용 출시 — 온디바이스 화자분할 SDK 구매 가능 G-10

1 시장 분석

출처	2025 추정	2030/2032 전망	CAGR	신뢰도
Grand View Research	$10.8B	공개 정보 없음	27.8%	[C]
Coherent Market Insights	$26.6B	$124.1B(2032)	24.6%	[C]
360iResearch	공개 정보 없음	$75.5B(2033)	공개 정보 없음	[C]
Grand View Research (SLM 전용)	$7.8B(2023)	$20.7B(2030)	15.1%	[C] G-06

< TAM/SAM/SOM >

< 온디바이스 AI 시장 규모 (복수 출처, 편차 주의) >

> *주의: 리서치사별 정의 범위 상이, TAM 3배 편차. 단일 출처 검증.*

시장 드라이버

- 프라이버시 규제 강화(GDPR, 개인정보보호법): 온디바이스 처리 수요 확대 G-12
- 2026년 기준 **20억대 이상** 스마트폰에서 로컬 sLM 실행 중 G-12
- 클라우드 추론 비용 → 단말 이전으로 통신사 서비스 원가 절감 가능 G-12

세부 지표	점수	판정 이유
TAM/SAM (10)	6	규모 충분하나 출처별 편차 3배, 신뢰도 [C]
CAGR (10)	8	24.6% 확인 (Coherent MI)
시장 타이밍 (10)	5	무료화 속도로 B2C 유료 창 급속 닫힘 E-01 E-02
규제/정책 (10)	7	GDPR, 개인정보보호법 강화 → 규제 기반 수요 G-12
소계	**26/40**	

< 시장매력도 채점 근거 >

② 기술 성숙도 분석

L3 기술	TRL	근거
OnDevice sLM (3B, 영어)	**8~9**	Snapdragon 8 Elite Gen 5: 220 tok/s G-03; Apple AFM 3B 양산 E-02; Galaxy S26 배포 E-01
OnDevice sLM (한국어)	**7~8**	KT 믿:음 2.3B Mini 오픈소스 E-03; ETRI Eagle 3B G-13
실시간 화자분할 (2인, 서버)	**8~9**	pyannoteAI DER 9.9% G-11; NVIDIA Streaming Sortformer G-09
실시간 화자분할 (2인, 온디바이스)	**7**	Picovoice Falcon SDK 상용 G-10; SpeakerKit 9.6x 속도 G-11; 배터리·DER 실측 부재
sLM 기반 통화 요약 (온디바이스)	**7~8**	SKT 에이닷 월 30건(클라우드 혼합) N-01; 온디바이스 전용 상용화 미확인

< TRL 매트릭스 >

4사분면 맵

```
        High TRL (7~9)
              |
[유지]        |      [베팅]
sLM 영어      |      sLM 한국어 특화
(8~9)         |       화자분할 온디바이스(7)
-------------------------|-------------------------
              |
[탐색]        |      [Watch]
              |       프라이버시 보존 화자분할
              |       (SMC+동형암호 결합, 초기)
        Low TRL (1~6)

Low Disruption ←——→ High Disruption
```

Criterion	Assessment	Evidence
Specific	명확	OnDevice sLM 기반 통화 분석 서비스 상용화
Measurable	부분적	정확도/배터리/지연시간 KPI 미정의 [D]
Achievable	가능	TRL 7~8, Samsung/Apple 시연 중 E-01 E-02
Relevant	관련성 있음	프라이버시(GDPR) + 클라우드 비용 절감 G-12
Time-bound	미정	마일스톤(2026H2 등) 미제시

< SMART Test >

모델/HW	추론 속도	메모리 (INT4)	출처
Snapdragon 8 Elite Gen 5 / 3B	**220 tok/s**	1.5GB	G-03
Apple A19 Pro / ~3B	~50~80 tok/s (추정)	—	공식 미공개
iPhone 14 A16 / Phi-3-mini 3.8B	12 tok/s	—	G-08

< 성능 벤치마크 >

< sLM 추론 성능 >

양자화 표준: FP16 학습 → INT4 배포 (4x 메모리 감소, 품질 손실 ~1~3%), GPTQ/AWQ 사실상 표준 수렴 G-04

시스템	DER (2인)	처리 방식	출처
pyannoteAI	**9.9%**	서버/클라우드	G-11
NVIDIA Streaming Sortformer	~10%+	서버/GPU	G-09
Picovoice Falcon	공개 정보 없음	완전 온디바이스	G-10
SpeakerKit (Argmax)	pyannote v3 동급	온디바이스 (Apple Silicon)	G-11

< 화자분할 성능 >

논문	핵심	출처
"Demystifying Small Language Models for Edge Deployment" (ACL 2025)	스마트폰 HW별 sLM 지연·메모리 실측 벤치마크 최초 체계화	P-01
"Edge-First Language Model Inference" (arXiv 2505.16508)	TGS·TTFT·전력 소모 3차원 트레이드오프 분석	P-02
"Unifying Diarization, Separation, ASR" (OpenReview 2025)	UME: 화자분할+음성분리+ASR 통합 학습 → 개별 최고 성능 개선	P-03
"SDBench" (arXiv 2507.16136)	13개 데이터셋 통합 오픈벤치마크; SpeakerKit 9.6x 속도 발견	P-04
"Benchmarking Diarization Models" (arXiv 2509.26177)	pyannoteAI 11.2% DER 1위, DiariZen 13.3% 오픈소스 최고	P-05
"Lightweight Real-Time Speaker Diarization" (EURASIP 2024)	RTF 0.1 이하, 5.5초 고정 지연 → CPU 온디바이스 가능	P-06
"Privacy-preserving Automatic Speaker Diarization" (arXiv 2210.14995)	SMC+Secure Hashing으로 서버 노출 없이 화자분할 가능	P-07
"Fast On-device LLM Inference with NPUs" (ASPLOS 2025)	NPU 특화 LLM 추론 최적화 체계화	P-08
"Scaling LLM Test-Time Compute with Mobile NPU" (arXiv 2509.23324)	스마트폰 NPU 추론 시간 스케일링·에너지 효율 분석	P-09

< 학술 연구 동향 (research-deep 수집) >

3 경쟁 환경

기업	서비스/프로젝트	단계	sLM 모델	차별화 요소	출처
Apple	SpeechAnalyzer API (WWDC25)	상용	AFM 3B (2bit)	시스템 스토리지, **무료**, KV 캐시 37.5% 절감	E-02
Samsung	Galaxy S26 (Feb 2026)	상용	Gauss 2.x 3~7B	NPU LoRA hot-swap, 보이스피싱 탐지, **무료**	E-01
Qualcomm	Snapdragon 8 Elite Gen 5	상용	참조 HW	**220 tok/s**, NPU 60 TOPS	G-03
Google	Gemini 2.5 Native Audio	상용	Gemini Nano	다화자 전사, Pixel 배포	G-16
SKT	A.phone (에이닷전화)	파일럿	클라우드 혼합	통화요약 월 30건, **유료화 연기**	E-04 N-01
KT	믿:음 2.0 Mini	상용	2.3B (온디바이스)	오픈소스, KoDarkBench 1위	E-03
NTT Docomo	SyncMe	상용	개인 AI 에이전트	습관 학습·선제 제안	N-02
ETRI	Eagle 3B	오픈소스	한국어 특화 3B	한국어 효율 우위, 2025년 7B 예정	G-13

< Gap Analysis 비교표 >

축	2026-03-03	2026-03-10	변화
보이스피싱 탐지	SKT/KT 상용	Samsung S26 **무료** 탑재	차별화 소멸
sLM 성능	commodity 판정	220 tok/s, 기술장벽 부재	경쟁 불가능
온디바이스 화자분할	미평가	Picovoice/SpeakerKit 상용	오픈마켓 SDK 존재
PQC E2E 암호화	유일 차별화축 (TRL 5~6)	상태 불변	여전히 기회이나 일정 불명

< 차별화 축 변화 (이전 대비) >

기업 발언 직접 인용

> *"에이닷 유료화 타이밍을 다각도로 재검토 중. 현재 AI 기술로 유료 서비스에 필요한 성능 수준을 달성할 수 있는지 평가하고 있다." — SKT CTO, MWC Barcelona 2026* E-04

> *"Galaxy S26은 세계 최초 내장 프라이버시 디스플레이와 함께 온디바이스 Gauss AI로 통화 요약·번역·보이스피싱 탐지를 무료 제공." — Samsung Global Newsroom* E-01

> *"믿:음 K 2.5 Pro를 공개하며 고난도 추론 능력 강화. 2.3B Mini 온디바이스 모델은 AICC·법률·금융 도메인에서 실서비스 적용 중." — KT 공식 보도자료* E-03

> *"SpeechAnalyzer는 완전 온디바이스로 동작하며 앱 번들 크기를 늘리지 않는다." — Apple Developer Documentation* E-02

출원인	특허번호	제목	관할	출처
Samsung	US20230419979A1	Online Speaker Diarization (Local/Global Clustering)	USPTO	T-01
Google	US12125501B2	Face-aware Speaker Diarization for Transcripts	USPTO	T-02
Samsung	US11074910B2	Electronic Device for Recognizing Speech	USPTO	T-03

< 특허 동향 >

- USPTO 2024 AI 특허 적격성 확대: "특정 기술 문제 해결에 AI 적용" 시 특허 가능 G-17
- **통신사 기회 영역**: 통신망 데이터(통화 패턴, 네트워크 신호) + 온디바이스 sLM 결합 — 빅테크 출원 미확인 → 선점 가능

4 전략 권고

요소	평가	점수	결론
차별화 중요도	sLM+화자분할 모두 commodity	Low (3/10)	Borrow 우선
내부 역량	KT 믿:음 + SKT 인프라 보유	Medium (6/10)	Borrow+Build 가능
시장 진입 시간	Feb 2026 무료화 시작	짧음 (<12mo)	창 빠르게 닫힘
시장 긴급도	WTP 미검증, 규제 드라이버만 존재	Medium (5/10)	Build 연기 고려
기술 격차	공개/상용 기술, 특허 약함	Low (<1yr)	Buy 불필요

< 3B 의사결정 경로 >

판정: Borrow + Targeted Build + B2B 선회

```
IF (differentiation_importance = Low) AND (tech_gap = Low):
    → BUY 불필요 (공개/상용 기술 충분)

ELIF (market_window < 12mo) AND (WTP = 미검증):
    → BUILD 전면 투자 부적합 (ROI 불확실)

결론:
    → BORROW (화자분할 SDK: Picovoice Falcon) + BUILD (한국어 파인튜닝: ETRI Eagle/KT 믿:음)
    → B2B 프라이버시 포지셔닝으로 선회 (기업 콜센터·금융사)
    → B2C 유료 서비스 WTP 검증 완료까지 연기
```

#	평가 항목	세부1 (10)	세부2 (10)	세부3 (10)	세부4 (10)	소계 (40)
1	**고객가치**	7 pain point 명확하나 대체제 무료화 E-01	6 기술 명확, 비즈니스 미검증	4 Samsung/Apple 무료 → 우위 없음 E-02	4 WTP 미검증 [D] E-04	**21**
2	**시장매력도**	6 TAM $10~$26B 편차 큼 [C] G-06	8 CAGR 24.6% 확인	5 무료화로 유료 창 축소 E-01	7 GDPR 규제 강화 G-12	**26**
3	**기술경쟁력**	7 TRL 7~8 확인 G-03	4 글로벌 빅테크 특허 선점 [D] T-01	5 공개/상용 기술, 모방 용이	5 글로벌 표준 따름, 한국어 벤치마크 부재	**21**
4	**경쟁우위**	3 후발주자 (Samsung/Apple 무료 선점)	4 차별화 기술 부재	5 빅테크 HW 통합 추격 불가	6 B2B 기회 있으나 독점성 없음	**18**
5	**실행가능성**	7 KT 믿:음+SKT 인프라 보유 E-03	5 매출 모델 미정의 [D]	5 마일스톤 미제시	4 미검증 항목 다수	**21**
	총점					**107/200**

< 200점 채점표 >

종합 판정: 재검토 (80~119 구간)

항목	이전 (120)	현재 (107)	변화	주 원인
고객가치	26	21	**-5**	SKT 에이닷 유료화 연기 → WTP 미검증 신호
시장매력도	29	26	-3	무료화 위협 확대 (Samsung S26 Feb 2026)
기술경쟁력	22	21	-1	TRL 확인되었으나 특허 약함 추가 발견
경쟁우위	20	18	-2	차별화 축 완전 소멸
실행가능성	23	21	-2	ROI 경로 불명확화

< 이전 대비 점수 변화 (-13점) >

후속 조건 체크리스트

- [ ] **0~1개월**: Picovoice Falcon / SpeakerKit SDK 평가 계약 — 한국어 통화 환경 DER 자체 측정
- [ ] **1~2개월**: Snapdragon 8 Elite / Exynos 2600 기기 기준 배터리 영향 측정 (30분 연속 통화)
- [ ] **2~3개월**: KT 믿:음 Mini 또는 ETRI Eagle 기반 통화 특화 파인튜닝 실험
- [ ] **3~4개월**: B2B 프로토타입 (기업 콜센터 프라이버시) — WTP 조사 병행
- [ ] **6~12개월**: 통신사 고유 데이터 + sLM 결합 특허 출원 (USPTO AI 적격성 확대 활용 G-17)
- [ ] **지속**: PQC E2E 병렬 진행 (2027년+ 통합 검토)

5 교차검증 결과

validator 판정: **UNCERTAIN** — 핵심 결론을 뒤집는 수준은 아니나 인용 완결성에 이슈 존재.

#	이슈	심각도	처리 방식
V-01	P-01~P-09 논문 9건 References 등재 후 본문 미인용	높음	**해소** — 최종 보고서 2. 기술 성숙도 분석에 학술 동향 테이블 추가, 전 논문 인용 완료
V-02	G-01,02,04,05,07,08,14,15,N-02 본문 미인용	중간	**해소** — 최종 보고서에서 해당 소스 인용 추가 (G-04 양자화, G-08 ETRI, G-13 Eagle 등)
V-03	prior N-12, prior N-14 (SKT 7,000억/KT 1조) References 미등재	높음	**잔존** — 이전 리포트 출처로 현재 References에 재등재 곤란. 최종 보고서에서 해당 수치 직접 인용 제거
V-04	"B2B 경쟁사 없음" 주장에 직접 근거 없음	중간	**잔존** — AWS Transcribe/Azure Speaker 등 기업용 솔루션 존재 인정. 단, 통신사 특화 B2B 솔루션은 미확인
V-05	Apple A19 Pro 추론 속도 추정치 공개 소스 없음	낮음	**해소** — 최종 보고서에서 "추정, 공식 미공개" 명시

최종 판정: PARTIAL — V-03(이전 리포트 수치)과 V-04(B2B 경쟁 현황) 2건 잔존. 핵심 결론(107/200, 재검토)에 영향 없음.

References

#	출처	URL	유형	날짜	신뢰도
G-01	V. Chandra — On-Device LLMs: State of the Union, 2026	링크	blog	2026-01	[B]
G-02	AssemblyAI — Top 8 Speaker Diarization Libraries and APIs 2026	링크	blog	2026	[B]
G-03	Futurum / Findarticles — Snapdragon 8 Elite Gen 5: 220 tokens/sec	링크	news	2025	[B]
G-04	Microsoft — INT4 Quantization Practical Guide (GPTQ/AWQ)	링크	blog	2026-02	[B]
G-05	PR Newswire — Samsung Galaxy S26 On-Device SLM Reasoning	링크	news	2025-12-25	[B]
G-06	Grand View Research — Small Language Model Market 2023-2030	링크	report	2024	[C]
G-07	Deloitte — 2026 TMT Predictions	링크	report	2025	[B]
G-08	ETRI Trends — 온디바이스 소형언어모델 기술개발 동향	링크	paper	2025	[A]
G-09	NVIDIA — Streaming Sortformer Real-Time Speaker Diarization	링크	news	2025-08-21	[A]
G-10	Picovoice — Falcon On-Device Speaker Diarization	링크	official	2025	[A]
G-11	pyannoteAI — Speaker Diarization DER Benchmark	링크	official	2025	[A]
G-12	Edge AI and Vision Alliance — On-Device LLMs in 2026	링크	blog	2026-01	[B]
G-13	AI타임스 — ETRI Eagle 3B 한국어 sLM 오픈소스 공개	링크	news	2024-11	[B]
G-14	Apple Developer — WWDC25 SpeechAnalyzer Session 277	링크	official	2025	[A]
G-15	Google Developers Blog — MediaTek NPU and LiteRT	링크	official	2025	[A]
G-16	Google — Gemini 2.5 Native Audio Model Updates	링크	official	2025-2026	[A]
G-17	Mintz / USPTO — 2024 AI Patent Eligibility Guidance Update	링크	official	2024-07	[A]
N-01	뉴시스 — SKT T전화 에이닷 탑재, 통화요약 월 30건 제한	링크	news	2024-10-15	[B]
N-02	Ubergizmo — NTT Docomo SyncMe Personal AI Agent at MWC 2026	링크	news	2026-03	[B]
E-01	Samsung Global Newsroom — Galaxy S26 Unpacked 2026	링크	official	2026-02-25	[A]
E-02	Apple ML Research — Foundation Models 2025 Updates	링크	official	2025	[A]
E-03	KT / 파이낸셜뉴스 — 믿:음 K MWC26 공개, 믿:음 2.0 Mini 2.3B	링크	official	2026-02-26	[A]
E-04	SKT Newsroom — MWC 2026 에이닷 유료화 재검토	링크	official	2026-03	[A]
P-01	ACL 2025 — Demystifying Small Language Models for Edge Deployment	링크	paper	2025	[A]
P-02	arXiv:2505.16508 — Edge-First Language Model Inference	링크	paper	2025-05	[A]
P-03	OpenReview — Unifying Diarization, Separation, ASR (UME)	링크	paper	2025	[A]
P-04	arXiv:2507.16136 — SDBench: Speaker Diarization Benchmark	링크	paper	2025-07	[A]
P-05	arXiv:2509.26177 — Benchmarking Diarization Models	링크	paper	2025-09	[A]
P-06	EURASIP JASMP — Lightweight Real-Time Speaker Diarization	링크	paper	2024	[A]
P-07	arXiv:2210.14995 — Privacy-preserving Automatic Speaker Diarization	링크	paper	2022	[A]
P-08	ASPLOS 2025 — Fast On-device LLM Inference with NPUs	링크	paper	2025	[A]
P-09	arXiv:2509.23324 — Scaling LLM Test-Time Compute with Mobile NPU	링크	paper	2025-09	[A]
T-01	Samsung — US20230419979A1 Online Speaker Diarization	링크	patent	2023	[A]
T-02	Google — US12125501B2 Face-aware Speaker Diarization	링크	patent	2024	[A]
T-03	Samsung — US11074910B2 Electronic Device for Recognizing Speech	링크	patent	2021	[A]