WTIS V4.1

주간 기술 동향: AXOps (2026-W10)

2026-03-06 | 2026-03-06_weekly-axops.md

경영진 요약

세부기술	신호	핵심 내용	분석
FeedBackOps Meta Prompt Eng.	🟢 평온	DSPy 생태계 안정적 발전, 신규 돌파 없음	Quick
EvalOps KMS 성능평가	🟢 평온	LLM-as-Judge 80-90% 인간 수준 합의, 플랫폼 성숙 중	Quick
학습 배포 통합 파이프라인	🟡 주목	AgentOps 등장(MLOps 진화형), Policy-as-Code 트렌드, CoreWeave-W&B $1.7B 인수	Deep
하이브리드 GPU Orchestration	🟡 주목	LG MWC Trusted Orchestration + 파주 AIDC 12만장 GPU, NVIDIA Run:ai 2x 활용률, P/D Disaggregation 패러다임	Deep

🟢 Quick 요약 (변화 미미)

FeedBackOps Meta Prompt Eng.

DSPy 프레임워크(Stanford NLP)가 프롬프트 자동 최적화 분야의 사실상 표준으로 안정화. MIPROv2(Bayesian Optimization), COPRO(Coordinate Ascent), SIMBA(Stochastic Mini-Batch) 등 옵티마이저가 운영 안정 단계. Meta prompt-ops(오픈소스), Microsoft PromptWizard(피드백 기반 자기진화), FIPO(Nature 발표, 피드백 통합 최적화) 등 연구가 지속되나 급격한 패러다임 전환 시그널은 미감지.

EvalOps KMS 성능평가

LLM-as-Judge가 인간 평가자와 80-90% 합의 수준에 도달하며 실용 단계 진입. RAGAS가 reference-free faithfulness/relevance 메트릭을 도입하여 수동 큐레이션 부담을 90% 절감. Amazon Bedrock에서 RAG 평가 + LLM-as-Judge가 GA 전환. 5대 평가 플랫폼(Maxim AI, LangSmith, Arize Phoenix, Ragas, DeepEval)이 생태계를 형성하며 시장 성숙 단계. 2026년 2월 "Case-Aware LLM-as-Judge for Enterprise RAG"(arXiv) 논문이 엔터프라이즈 RAG 환경의 맞춤형 평가 방법론을 제시.

🟡 Deep 심층 분석

학습 배포 통합 파이프라인 — 🟡 주목

기술 동향

패러다임 진화: MLOps → LLMOps → AgentOps

2026년 AI 운영 프레임워크는 세 계층의 병렬 성숙 구조를 형성하고 있다 G-01.

- **MLOps (성숙)**: 피처 스토어, 모델 훈련/튜닝, CI/CD for models, 모니터링(드리프트·지연·정확도), 자동 재훈련 워크플로우. MLflow, TFX, SageMaker Pipelines 등 도구 안정화.
- **LLMOps (부상)**: "프롬프트는 새로운 코드지만 버전 관리되지 않는다"는 문제를 핵심으로, 프롬프트 버전 관리, RAG 파이프라인 오케스트레이션, LLM 특화 평가 프레임워크, 토큰 비용 최적화가 핵심 컴포넌트 G-02.
- **AgentOps (초기)**: 자율 에이전트의 비결정론적 행동 특성으로 인해 전통 MLOps로는 관리 불가. 모니터링→이상탐지→근본원인분석→해결의 4단계 프레임워크 제시 G-03.

5대 최신 MLOps 기법 (2026)

- **Policy-as-Code**: 공정성, 데이터 계보, 규제 준수를 CI/CD에 실행 가능한 코드로 자동 임베딩. EU AI Act, SOC2, GDPR 대응 G-04, G-05
- **AgentOps**: LLM 기반 자율 에이전트 전용 운영 프레임워크
- **운영 설명가능성(XAI)**: 런타임 설명기를 MLOps 라이프사이클 전반에 통합
- **분산 MLOps**: 엣지·TinyML·연합 학습 파이프라인으로 프라이버시·지연 요구사항 대응
- **Green MLOps**: 에너지 메트릭, 탄소 추적, 효율 KPI를 운영 체계에 통합 G-06

MLflow 3.0 출시 (2025년 중반)

GenAI 특화 기능 대폭 강화 E-01: 계층적 트레이싱, LLM Judge 기반 평가, 피드백 수집 API, 애플리케이션 버전 관리(프롬프트·RAG·오케스트레이션 코드를 원자적 아티팩트로 관리). AWS SageMaker에 완전 관리형으로 제공 중 E-03.

오픈소스 업데이트

- **KServe**: HuggingFace Transformer v4.51.0, vLLM V1 지원, OpenAI 프로토콜 호환 G-07
- **Kubeflow 1.9**: Ray, Seldon, BentoML, KServe 통합 강화, LLM GPU 최적화

플레이어 동향

기업	동향	출처
CoreWeave	W&B를 $1.7B에 인수(2025-05). 컴퓨트+AI 개발자 플랫폼 수직 통합	E-02
Databricks	MLflow 3.0 출시. ISG 2025 Buyers Guide 4개 카테고리 Leader	E-01, G-09
Oracle	ISG 2025 ML/LLM Operations 전체 1위. 7개 카테고리 전부 Leader	G-09
AWS	SageMaker AI에 MLflow 3.0 완전 관리형 제공(2025-07)	E-03
Google Cloud	ISG 3개 카테고리 Leader. AI 특허 세계 1위(1,837건)	G-09, G-10
W&B (AgentOps)	1,400+ 기업 고객. AgentOps SDK: 400+ LLM 추적, 파인튜닝 비용 25배 절감 주장	G-08

< 주요 플레이어 테이블 >

시장 시그널

- MLOps 시장 2026년 $3~5B, CAGR 37~42% (기관별 편차 큼) G-11
- 2024년 MLOps 투자 $4.5B, 2026년 $7~8B 예상 G-12
- Gartner: AI 에이전트 플랫폼 기업 관심 1,445% 급증 G-13
- 85%의 ML 모델이 프로덕션 미도달 — 이 격차 해소가 시장 성장 핵심 동인
- **핵심 딜**: CoreWeave → W&B $1.7B (2025-05), Databricks → Tecton 통합 발표(2025) E-02

학술 동향 (주요 논문)

논문	핵심	출처
A Survey on AgentOps (Wang et al., 2025)	AgentOps 최초 종합 조사. intra/inter-agent 이상 분류, 4단계 프레임워크	P-01
Navigating MLOps (Stone et al., 2025)	9단계 통합 MLOps 라이프사이클, 5개 성숙도 모델 비교, 50개 도구 정리	P-02
Transitioning from MLOps to LLMOps (MDPI, 2025)	MLOps↔LLMOps 구조적 차이 규명, GPU/TPU 의존성, RLHF 요건 분석	P-03
Green MLOps to Green GenOps (MDPI, 2025)	판별형 AI vs 생성형 AI 에너지 소비 실증 비교	P-06

< 주요 논문 테이블 >

전략적 시사점

기회

- Policy-as-Code 기반 자동 규제 준수(EU AI Act, GDPR)를 CI/CD에 내재화하면 속도와 안전성 동시 확보 가능
- AgentOps 도구 생태계 초기 단계 — 조기 도입 시 표준화 주도권 확보 가능
- CoreWeave-W&B "컴퓨트+관측성" 수직 통합이 새 경쟁 공식 제시. 유사 번들링 전략 후발 적용 가능
- Green MLOps는 탄소 중립 목표 기업에서 MLOps 도입 정당화 신규 비즈니스 케이스

위협

- 클라우드 빅3의 수직 통합 심화 → 독립 MLOps 벤더 생존 공간 축소
- AgentOps 성숙도 부족: 비결정론적 행동의 프로덕션 디버깅 난이도 여전히 높음
- MLOps, LLMOps, AgentOps 도구 스택 병렬 증식 → 통합 전까지 기술 부채 축적 위험
- LLM 추론 비용이 전통 ML 대비 최대 100배 — 비용 최적화 없이는 프로덕션 확장 불가

하이브리드 GPU Orchestration — 🟡 주목

기술 동향

오케스트레이션 레이어 성숙: 스케줄링 → 인퍼런스 서빙 최적화

GPU 오케스트레이션이 단순 스케줄링을 넘어 인퍼런스 서빙 최적화로 중심축 이동. Kubernetes DRA가 v1.35에서 stable 승격·기본 활성화되어 GPU를 first-class 스케줄링 자원으로 처리하는 기반 완성 G-06b. 그러나 well-run 클러스터도 GPU 평균 활용률 20~30% 문제 지속 G-05b.

P/D Disaggregation (Prefill-Decode 분리) 패러다임

2025~2026년 인퍼런스 핵심 혁신. Prefill(프롬프트 처리)과 Decode(토큰 생성)를 물리적으로 분리하여 독립 최적화 G-07b. NVIDIA Dynamo가 이를 프로덕션 스케일로 구현한 오픈소스 프레임워크로, KV캐시 인식 라우터·GPU Resource Planner를 포함하며 DeepSeek-R1 기준 **처리량 30배 향상** 달성 G-08b.

vLLM 생태계 심화

- **LMCache**: KV 캐시 GPU 외부 오프로드·엔진 간 공유. P/D 분리 지원 G-13b
- **vLLM AMD ROCm 지원**: 2026-02 AMD ROCm 전용 어텐션 백엔드 최적화 공개 G-14b
- **llm-d (Red Hat)**: KV캐시 인식 라우팅 분산 스케줄링 프레임워크 G-13b

Kthena: Kubernetes-Native 인퍼런스 오케스트레이션

Volcano 커뮤니티가 2026-01 CNCF 통해 공개. vLLM·SGLang·Triton·TorchServe 지원, KV캐시 인식 라우팅, P/D 분리, 토폴로지 인식 스케줄링 내장 G-11b.

NVIDIA KAI Scheduler + Ray 통합

KubeRay에 네이티브 통합 — Gang Scheduling·우선순위 큐·워크로드 선점 기능 제공. 학습과 인퍼런스가 동일 GPU 풀 공유하는 멀티워크로드 환경 효율화 G-10b.

AMD ROCm 7.0 + SkyPilot 멀티클라우드

AMD ROCm 7.0이 엔터프라이즈급 클러스터 관리 도구를 포함하며 SkyPilot 통합으로 CUDA 워크로드의 AMD Instinct MI300X 이전 경로 제공. 20개+ 클라우드를 단일 YAML로 추상화 G-12b.

플레이어 동향

기업	동향	출처
NVIDIA	Run:ai v2.24 — GPU 활용률 2x, TTFT 44~61x 개선. Dynamo 오픈소스(P/D, 처리량 30x). KAI Scheduler→Ray 통합	G-01b, G-08b, G-10b
NVIDIA (AI-RAN)	Nokia와 Grace Hopper 200에서 AI+RAN 동시 처리 실증. 2026 시험, 2027 상용 출시	G-15b
Samsung	MWC 2026: NVIDIA Aerial 기반 AI-RAN 멀티셀 검증. GPU Lock-In 탈피 CPU 옵션도 검증	G-17b
Nokia	MWC 2026: SMO rApp 마켓플레이스 출시. BT·Elisa·NTT DoCoMo·Vodafone과 AI-RAN 배포	G-15b
LG (LG U+/AI Research)	K-엑사원 4대 핵심 중 "Trusted Orchestration" — Planning·Execution·Evaluation·Review AI 협업 조율. 파주 AIDC GPU 12만장·200MW·2027 준공	N-01b, N-02b
CoreWeave	IPO 후 NVIDIA $20억 추가 투자. Rubin 플랫폼 최초 배포 클라우드(2026 H2). 2026 매출 $120억(YoY +134%)	G-18b
SkyPilot	v0.11: 멀티클라우드 풀, CoreWeave 공식 지원(InfiniBand), AMD ROCm 7.0+Ray 통합	G-03b
Google	Ironwood TPU(7세대, 인퍼런스 특화 FP8 네이티브). Anthropic에 Trillium TPU 수십만 개 계약	G-21b

< 주요 플레이어 테이블 >

시장 시그널

- GPU-as-a-Service: 2026년 **$73.4억** → 2031년 **$259.4억** (CAGR 28.7%) G-22b
- 멀티/하이브리드 클라우드 세그먼트 CAGR 29.4%로 최고 성장 — 오케스트레이션 S/W가 핵심 드라이버
- AI 데이터센터 GPU 시장: 2026년 $128.3억 → 2035년 $771.5억 (CAGR 22.1%) G-23b
- 인퍼런스 세그먼트가 시장 최대 점유 — 실시간 AI 앱 수요 주도
- **핵심 딜**: CoreWeave — NVIDIA $20억 투자, Meta $142억 계약, OpenAI $224억 계약, Perplexity GB200 전용 클러스터 (2026-03-04) G-18b
- **LG 파주 AIDC**: GPU 12만장·200MW·2027 준공. "One Team LG" 전략 N-01b

학술 동향 (주요 논문)

논문	핵심	출처
Nexus: Proactive Intra-GPU Disaggregation (2025)	단일 GPU 내 P/D 분리, SM 동적 재할당	P-01b
RAPID-Serve (2026-01)	동일 GPU P/D 동시 실행, Adaptive Resource Mgmt	P-02b
FlowPrefill (2026-02)	연산자 레벨 Fine-grained Preemption, 멀티-SLO 최적화	P-03b
Disaggregated P/D for Multi-Vendor GPUs (2025-09)	이종 GPU 환경 P/D 분리 인퍼런스	P-04b
HeteroScale (2025-08)	토폴로지 인식 오토스케일러, P/D 풀 공동 스케일링	P-05b
Disaggregated Multi-Stage MLLM (2025-12)	멀티모달 LLM 3단계(비전·프리필·디코딩) 분리 파이프라인	P-06b
Token Management in Multi-Tenant (2026-03)	멀티테넌트 인퍼런스 플랫폼 토큰 관리 최적화	P-07b

< 주요 논문 테이블 >

전략적 시사점

기회

- GPU 평균 활용률 20~30% 문제 → 오케스트레이션 솔루션의 명확한 ROI. Run:ai 벤치마크(2x)가 비즈니스 케이스 실증
- P/D Disaggregation + KV캐시 라우팅은 동일 GPU 투자로 처리량 수배 향상하는 검증된 아키텍처. Dynamo(오픈소스)·Kthena(CNCF)로 즉시 채택 가능
- SkyPilot + AMD ROCm 7.0 → NVIDIA 종속 해소 실용적 경로. 네오클라우드 활용 비용 절감
- 통신 AI-RAN에서 GPU 오케스트레이션 수요 신규 창출 — Nokia·Samsung MWC 2026 상용화 타임라인 확정

위협

- NVIDIA 수직 통합(H/W → Run:ai → Dynamo → NIM) 심화로 단일 벤더 의존 고착화 위험
- GPU 공급 병목 지속 — CoreWeave $300억+ 백로그, Anthropic TPU 선점 사례
- 오픈소스 분열(vLLM·SGLang·Triton·Dynamo·Kthena 등) — 표준 미확립으로 기술 선택 복잡도 상승
- LG 파주 AIDC 2027 준공 예정 — 국내 GPU 인프라가 글로벌 대비 1~2년 지연

종합 시사점 및 후속 조치

기술 간 교차 시사점

1. **MLOps↔GPU Orchestration 수렴**: MLOps의 AgentOps 진화와 GPU Orchestration의 인퍼런스 최적화가 동일한 문제("복합 AI 시스템의 효율적 프로덕션 배포")를 양쪽에서 접근 중. CoreWeave-W&B 인수($1.7B)가 이 수렴을 상징하는 대표 사례.
2. **P/D Disaggregation이 전 스택에 파급**: GPU 레벨의 P/D 분리(Dynamo, Kthena)가 상위 MLOps/LLMOps 파이프라인의 서빙 아키텍처를 근본적으로 재설계 요구. 기존 단일 모델 엔드포인트 기반 배포 파이프라인이 분산 인퍼런스 파이프라인으로 전환.
3. **통신 인프라의 GPU 수요 신규 창출**: Nokia·Samsung의 AI-RAN 상용화(2026 시험, 2027 출시)와 LG 파주 AIDC(GPU 12만장)가 통신+AI 인프라 융합을 가속. GPU Orchestration이 데이터센터를 넘어 네트워크 인프라로 확장되는 시그널.
4. **Green MLOps와 GPU 효율화의 교차점**: IEA 예측(데이터센터 전력 수요 2배 증가)과 GPU 활용률 20~30% 문제가 만나는 지점에서, 탄소 인식 스케줄링 + GPU fractional 할당이 비용과 지속가능성을 동시에 해결하는 경로로 부상.

후속 조치 제안

- LG 파주 AIDC Trusted Orchestration 전략의 L2 기술별 영향도 분석 필요 시 → `/wtis standard` 검증 제안
- 다음 주 모니터링: NVIDIA GTC 2026 발표 내용 (Dynamo/Run:ai 업데이트 예상)

References

#	출처	URL	유형	날짜	신뢰도
G-01	Covasant — MLOps, LLMOps, & AgentOps Guide	링크	업계 블로그	2025~2026	[B]
G-02	Medium/CodeX — MLOps in 2026: From MLflow to LLMOps	링크	블로그	2026-02	[C]
G-03	XenonStack — AgentOps: Next Evolution in AI Lifecycle	링크	업계 블로그	2025~2026	[B]
G-04	KDnuggets — 5 Cutting-Edge MLOps Techniques 2026	링크	전문 미디어	2025~2026	[B]
G-05	TechTarget — MLOps Governance Strategies	링크	전문 미디어	2025~2026	[B]
G-06	DevOps.com — MLOps for Green AI	링크	전문 미디어	2025	[B]
G-07	KServe GitHub Releases	링크	오픈소스 공식	2025	[A]
G-08	Softcery — 8 AI Observability Platforms Compared	링크	업계 분석	2025	[B]
G-09	ISG — ML/LLM Operations 2025 Buyers Guide	링크	애널리스트	2025	[A]
G-10	Axios — Google Dominates AI Patent Applications	링크	주요 언론	2025-05	[B]
G-11	Precedence Research — MLOps Market Size	링크	시장조사	2025~2026	[C]
G-12	Quick Market Pitch — MLOps Platforms Funded (July 2025)	링크	업계 분석	2025-07	[C]
G-13	Getmaxim.ai — Top 5 AI Agent Observability 2026	링크	업계 블로그	2026	[C]
G-14	Conf42 MLOps 2026	링크	컨퍼런스	2026	[B]
E-01	Databricks — MLflow 3.0	링크	기업 공식	2025	[A]
E-02	CoreWeave IR — W&B Acquisition Complete	링크	공식 IR	2025-05-05	[A]
E-03	AWS — MLflow 3.0 on SageMaker AI	링크	공식 발표	2025-07	[A]
P-01	Wang et al. — A Survey on AgentOps	arXiv:2508.02121	학술 논문	2025-08	[A]
P-02	Stone et al. — Navigating MLOps	arXiv:2503.15577	학술 논문	2025-03	[A]
P-03	MDPI — Transitioning from MLOps to LLMOps	링크	동료 심사	2025-01	[A]
P-04	Joshi — LLMOps, AgentOps, and MLOps Review	ResearchGate	학술 리뷰	2025	[B]
P-05	Chernigovskaya et al. — Standardized LLMOps Process Model	링크	컨퍼런스 논문	2025	[A]
P-06	MDPI — Green MLOps to Green GenOps	링크	동료 심사	2025	[A]

< MLOps Pipeline 출처 >

#	출처	URL	유형	날짜	신뢰도
G-01b	NVIDIA — Maximizing GPU Utilization with Run:ai and NIM	링크	공식 블로그	2026-02	[A]
G-02b	NVIDIA — GPU Fractioning: 77% Throughput at Half Allocation	링크	공식 블로그	2026-02	[A]
G-03b	CoreWeave — SkyPilot Multi-Cloud Orchestration	링크	기업 블로그	2026	[B]
G-05b	ScaleOps — Kubernetes GPU Resource Management	링크	전문 블로그	2026	[B]
G-06b	AceCloud — Multi GPU Orchestration in K8s 2026	링크	전문 블로그	2026	[B]
G-07b	vLLM Docs — Disaggregated Prefilling	링크	공식 문서	2026	[A]
G-08b	NVIDIA — Introducing Dynamo Distributed Inference	링크	공식 블로그	2025	[A]
G-10b	NVIDIA — Gang Scheduling in Ray with KAI Scheduler	링크	공식 블로그	2026	[A]
G-11b	CNCF — Introducing Kthena	링크	CNCF 공식	2026-01-28	[A]
G-12b	AMD ROCm — Autoscaling with Ray, ROCm 7.0, SkyPilot	링크	공식 블로그	2026	[A]
G-13b	llm-d.ai — KV-Cache Wins	링크	공식 블로그	2026	[B]
G-14b	vLLM — High-Performance Inference on AMD ROCm	링크	공식 블로그	2026-02-27	[A]
G-15b	Nokia — AI-RAN Momentum #MWC26	링크	공식 보도자료	2026-03-01	[A]
G-17b	The Meridiem — Samsung AI-RAN Breaks GPU Lock-In	링크	전문 언론	2026-03-02	[B]
G-18b	CoreWeave IR — Extends Cloud with NVIDIA Rubin	링크	공식 IR	2026	[A]
G-20b	GlobeNewswire — VAST Data Polaris	링크	공식 보도자료	2026-02-25	[A]
G-21b	Google — Ironwood TPU for the Age of Inference	링크	공식 블로그	2026	[A]
G-22b	Mordor Intelligence — GPU as a Service Market 2026-2031	링크	시장조사	2026	[B]
G-23b	Precedence Research — AI Data Center GPU Market	링크	시장조사	2026	[B]
N-01b	인사이트코리아 — LGU+ 파주 GPU 12만장 DC	링크	한국 언론	2026-03	[B]
N-02b	아주경제 — LG그룹 파주 AIDC 2027 준공	링크	한국 언론	2026-03-02	[B]
N-03b	전자신문 — 정숙경 LG유플러스 파주 AIDC 전략	링크	한국 언론	2026-03-05	[B]
P-01b	Nexus: Proactive Intra-GPU P/D Disaggregation	arXiv:2507.06608	학술 논문	2025	[A]
P-02b	RAPID-Serve: P/D Intra-GPU Disaggregation	arXiv:2601.11822	학술 논문	2026-01	[A]
P-03b	FlowPrefill: Decoupling Preemption from Prefill	arXiv:2602.16603	학술 논문	2026-02	[A]
P-04b	Disaggregated P/D for Multi-Vendor GPUs	arXiv:2509.17542	학술 논문	2025-09	[A]
P-05b	HeteroScale: Coordinated Autoscaling for Disaggregated LLM	arXiv:2508.19559	학술 논문	2025-08	[A]
P-06b	Disaggregated Multi-Stage MLLM Inference	arXiv:2512.17574	학술 논문	2025-12	[A]
P-07b	Token Management in Multi-Tenant AI Inference	arXiv:2603.00356	학술 논문	2026-03	[A]

< GPU Orchestration 출처 >