

주간 기술 동향: Agentic AI (2026-W14)

2026-03-24

Executive Summary

이번 주 핵심: GTC 2026을 기점으로 GPU 인프라의 "학습→추론" 구조적 전환이 가속되는 가운데, 에이전트 프레임워크 4강 (OpenAI·Anthropic·Google·Microsoft)이 동시다발적으로 프로덕션급 업데이트를 발표. NVIDIA Dynamo 1.0이 오픈소스 추론 OS로 정착하고, AT&T-Cisco-NVIDIA AI Grid가 에지 AI 대규모 상용 배포를 시작하면서 "클라우드→에지" 추론 인프라 이동이 현실화.

Layer 2	세부기술	신호	핵심 내용
Trusted Multi-Agent Orchestration	Intelligent Agent Orchestration	●	OpenAI SDK 0.13 tool search(3/23), Claude Code Channels(3/20), Google ADK 네이티브 A2A, MS Foundry Agent Service GA(3/16)
	Agent Oriented Orchestration	●	ReAcTree + hybrid plan-execute 표준 정착 유지, 신규 변화 없음
Model & Delta Foundry	하이브리드 GPU Orchestration	●	NVIDIA Dynamo 1.0 GA(3/16) Blackwell 7x 추론 향상, Vera Rubin \$1T 수주 전망, DDN 협업
	FeedbackOps: Meta-prompt Engineering	●	DSPy MIPROv2 안정, GEPA GPT-4.1 Mini 46.6%→56.6% AIME 개선
	EvaluationOps: KMS 성능 평가	●	RAGAS 표준 정착, LLM-as-judge 80-90% 인간 일치 유지
	데이터-학습-배포 파이프라인	●	MLOps→LLMOps 전환 지속, LoRA/PEFT 엔터프라이즈 표준화 진행
Hybrid AI Infra	On-Device sLM	●	OpenAI GPT-5.4 mini+nano(3/17), sLM-First 아키텍처 비용 60-70% 절감
	Edge AI	●	AT&T-Cisco-NVIDIA AI Grid 상용 배포(3/17), Akamai 4,400 에지 배포, TI NPU MCU(3/10)
	5G SA/6G(AI-RAN/SRv6)	●	MWC 발표 후속 정착 단계, 이번 주 신규 발표 없음
	실시간 화자분할(2인)	●	AssemblyAI Universal-3-Pro, Gladia Solaria-1 안정 유지
Self Evolving Architecture	Agentic Context Engineering	●	ACE(ICLR 2026) 생태계 성숙 지속, 신규 발표 없음
의도 파악 기술	Adaptive RAG	●	Agentic RAG 57%+ 도입 유지, CRAG 패턴 정착

신호 : ● 긴급 — 경쟁사 출시, 규제 변경, 기술 돌파 | ● 주목 — 주요 발표·논문·표준 변화 감지 | ● 평온 — 유의미 변화 없음

목차

Executive Summary

Quick 요약 (변화 미미)

Agent Oriented Orchestration

FeedbackOps (Meta-prompt Engineering)

EvaluationOps (KMS 성능평가)

MLOps Pipeline

5G SA/6G (AI-RAN/SRv6)

Speaker Diarization

Agentic Context Engineering

Adaptive RAG

Deep 심층 분석

Intelligent Agent Orchestration —  주목

하이브리드 GPU Orchestration —  주목

On-Device sLM —  주목

Edge AI —  주목

경쟁사 동향 (SKT / KT)

SKT

KT

규제 & 거버넌스

시행 임박 / 카운트다운

신규 발의 & 가이드라인

시사점

종합 시사점 및 후속 조치

이번 주 핵심 전환

후속 조치 권장

References

Quick 요약 (변화 미미)

Agent Oriented Orchestration

- ReAcTree + hybrid plan-execute 패턴이 산업 표준으로 정착 중. Plan-and-Execute 패턴(고추론 모델이 DAG 분해 → 경량 모델이 실행 → 재계획)이 주류. 이번 주 추가 변화 없음.

FeedbackOps (Meta-prompt Engineering)

- DSPy MIPROv2 옵티마이저와 GEPA 기반 자동 프롬프트 최적화가 안정 운영 중. GEPA는 GPT-4.1 Mini의 AIME 2025 수학 문제에서 46.6%→56.6%(+10pp) 개선 시연. BetterTogether 메타옵티마이저(프롬프트+가중치 순차 최적화) 패턴 확산.

EvaluationOps (KMS 성능평가)

- LLM-as-judge가 인간 평가자와 80-90% 일치율 유지. RAGAS가 RAG (Retrieval-Augmented Generation) 평가의 사실상 표준으로 정착. Langfuse + RAGAS + DeepEval 통합 평가 파이프라인 확산. 판정자 정렬(Judge Alignment) 연구 진행 중.

MLOps Pipeline

- MLOps→LLMOps 전환 가속 유지. LoRA (Low-Rank Adaptation)/PEFT (Parameter-Efficient Fine-Tuning)가 엔터프라이즈 파인튜닝 표준. Databricks, AWS, Azure, GCP 모두 LLMOps 기능 내장. 이번 주 신규 변화 없음.

5G SA/6G (AI-RAN/SRv6)

- W13에서 보고한 SKT-에릭슨 MoU(3/19), NVIDIA Aerial 오픈소스, OCUDU 재단 출범 등이 후속 정착 단계. 이번 주 추가 발표 없음. Chunghwa Telecom-에릭슨 5G-Advanced MoU(MWC 2026) 확인.

Speaker Diarization

- AssemblyAI Universal-3-Pro와 Gladia Solaria-1(103ms 부분 지연) 안정 운영 유지. pyannote 실시간 다이어리제이션 + LLM 기반 트랜스크립션 통합 연구 진행 중. 돌파구 수준 변화 없음.

Agentic Context Engineering

- ACE (Agentic Context Engineering) (ICLR 2026) 프레임워크의 오픈소스 생태계 점진적 성숙. ICSE 2026에서 AGENT 2026 워크숍 예정. 이번 주 신규 발표 없음.

Adaptive RAG

- Agentic RAG 프로덕션 도입률 57%+ 유지. CRAG (Corrective RAG) 패턴이 기업 배포 표준으로 정착. Higrass-RAG(적응형 라우팅 + 시맨틱 캐싱 + 이중 하이브리드 검색) 엔터프라이즈 배포 확산 중.

Intelligent Agent Orchestration — ● 주목

상세 리서치: 2026-03-24.research-agent-orchestration.md

이전 대비 변화

- 전주: Google Colab MCP Server 오픈소스, MCP 2026 로드맵 공개, MS Agent Framework GA 임박
- 금주: OpenAI Agents SDK 0.13 + tool search, Claude Code Channels(3/20), Google ADK 네이티브 A2A, MS Foundry Agent Service GA(3/16)
- 변화 방향: 프로토콜 표준화 완료 → 런타임 도구 효율화 + 멀티에이전트 프로덕션화 단계

기술 동향

- OpenAI Agents SDK 0.13 — tool search로 대규모 도구 생태계 효율화(3/23).**
Responses API tool search 지원 추가. 에이전트가 대규모 도구를 런타임에 지연 로드하여 토큰·캐시·지연 최적화. GPT-5.4가 tool search 네이티브 지원. voice agent(gpt-realtime-1.5 기반) 빌딩도 추가. G-01
- Claude Code Channels — MCP 서버 기반 외부 메시지 브릿지(3/20).**
`--channels` 플래그로 Telegram·Discord 메시지를 Claude Code 세션에 실시간 주입. MCP elicitation(v2.1.76+)과 결합하여 에이전트가 구조화된 입력을 인터럽트 없이 수집. MCP Python/TypeScript SDK 월간 다운로드 9,700만+. G-02
- Google ADK (Agent Development Kit) 네이티브 A2A (Agent-to-Agent) 지원.**
Agent Card 퍼블리싱 → 디스커버리 → 서브에이전트 활용 공식화. Cloud Run 및 Agent Engine 배포 지원으로 프로덕션 A2A 에이전트 원클릭 배포. G-03
- Microsoft Foundry Agent Service GA(3/16) + Agent Framework Q1 GA 임박.**
프라이빗 네트워킹, Voice Live, 엔터프라이즈급 평가 기능 포함. AutoGen·Semantic Kernel 통합 완료, A2A·MCP 프로토콜 지원. G-04
- VS Code 1.112 — Copilot 에이전트 자율성 확대 + MCP 서버 샌드박스(3/18).**
macOS·Linux MCP 서버 샌드박스, 모노레포 에이전트 커스터마이징 지원 확대. G-05

플레이어 동향

기업	동향	출처
OpenAI	Agents SDK 0.13(3/23): tool search, GPT-5.4 computer use, voice agent 지원	G-01
Anthropic	Claude Code Channels(3/20) Telegram/Discord 브릿지, MCP elicitation, Opus 4.6 agent teams	G-02
Google	ADK 네이티브 A2A, Agent Engine + Cloud Run 배포	G-03
Microsoft	Foundry Agent Service GA(3/16), Agent Framework Q1 GA 임박, VS Code 1.112 MCP 샌드박스	G-04 , G-05
Interloom	에이전트 'tacit knowledge' 문제 해결 \$16.5M VC(3/23, DN Capital 리드)	G-06
CrewAI	v1.10.1 MCP+A2A, 45,900+ Stars, 일간 1,200만 에이전트 실행	G-07

시장 시그널

투자 & M&A

- Interloom \$16.5M VC(3/23) — 에이전트 암묵지 문제 해결 **G-06**
- 에이전틱 AI 스타트업 평균 라운드 \$155M(Q4 2025~Q1 2026), 전기 대비 2배 **G-08**

시장 전망

- 글로벌 에이전틱 AI 시장 \$91~109억(2026) → \$1,390억(2034), CAGR 40.5% **G-08**
- Gartner: 2026년 말 엔터프라이즈 앱 40%에 에이전트 탑재(2025년 5% 미만) **G-09**
- Salesforce: 멀티에이전트 도입 2027년까지 67% 급증 **G-10**

도입 사례

- Global 2000 기업 72% AI 에이전트 프로덕션 배포(파일럿 넘어섬) **G-09**

연구 동향

- MAS-Orchestra: RL 기반 MAS 오케스트레이션, MASBENCH에서 10x 효율 달성 — "어떤 모델"에서 "어떻게 조율하느냐"로 학술 트렌드 전환 재확인 **P-01**

시장 수요

고객 페인포인트

- 에이전트 프레임워크 난립으로 선택 피로(4강 + CrewAI + LangGraph 경쟁)
- 에이전트 암묵지(tacit knowledge) 문제 — 명시적 프롬프트로 전달하기 어려운 도메인 지식

도입 장벽

- 엔터프라이즈 SSO·감사 트레일·거버넌스 미성숙(MCP 2026 로드맵에서 공식 인정)

시장 니즈

- 프레임워크 간 상호운용성 → A2A + MCP 듀얼 스택 지원이 사실상 표준

전략적 시사점

1. **MCP + A2A 듀얼 스택 필수** — Big Tech 4사 모두 양쪽 지원. 자사 에이전트 설계 시 두 프로토콜 대응 필수.
2. **Tool Search 패턴** — 도구 수 증가에 따른 토큰·지연 문제를 런타임에 해결. 자사 MCP 도구 확장 시 유사 메커니즘 검토.
3. **KT 에이전트 빌더 대응** — KT가 노코드 에이전트 제작 플랫폼을 MWC26에서 공개. B2B 에이전트 시장 선점 경쟁 가속.

하이브리드 GPU Orchestration — 🟡 주목

상세 리서치: [2026-03-24_research-gpu-orchestration.md](#)

이전 대비 변화

- 전주: SkyPilot Job Groups + Claude Code 자율 910회 실험, Ocean Network P2P 베타, AKS DRA+vGPU GA
- 금주: NVIDIA Dynamo 1.0 GA(3/16), Vera Rubin 플랫폼 공개, DDN-NVIDIA 추론 비용 최적화(3/17), Blackwell 7x 추론 향상
- 변화 방향: GPU 오케스트레이션 초점이 학습 → **추론 최적화**로 구조적 전환. Dynamo가 "AI 팩토리 OS"로 정착

기술 동향

- 1. **NVIDIA Dynamo 1.0 GA — 오픈소스 추론 OS 프로덕션 출시(3/16).**
데이터센터 규모 분산 추론 프레임워크. 분리형 서빙, 지능형 라우팅, 다층 KV 캐싱, 자동 스케일링. Blackwell GPU 추론 7x 향상. AWS·Azure·GCP·OCI + CoreWeave·Cursor·Perplexity·PayPal·Pinterest 등 프로덕션 배포. G-11
- 2. **Vera Rubin 플랫폼 — 칩 7종 + 랙 5종의 수직 통합(GTC 2026).**
NVL72 랙이 이전 대비 1/4 GPU로 동일 학습, 와트당 추론 10x, 토큰당 비용 1/10. Vera Rubin + Groq 3 LPX 조합으로 35x 처리량/MW. Jensen Huang 2027년 \$1T 수주 전망. G-12
- 3. **DDN-NVIDIA 협업 — 추론 비용 절감 + GPU 활용률 극대화(3/17).**
스토리지-컴퓨트 분리로 모델 로딩·KV 캐시 관리 최적화. G-13
- 4. **Dynamo + GKE (Google Kubernetes Engine) Inference Gateway — 클라우드 네이티브 추론 오케스트레이션.**
모듈형 오픈소스 컨트롤 플레인으로 이종 가속기 클러스터 통합 관리. G-14
- 5. **CoreWeave SkyPilot 백엔드 공식 지원.**
SkyPilot YAML/CLI에서 CoreWeave 클러스터 직접 잡 런칭. 이종 하드웨어 추상화 유지. G-15

플레이어 동향

기업	동향	출처
NVIDIA	Dynamo 1.0 GA(3/16), Vera Rubin 플랫폼, \$1T 전망, Blackwell 7x	G-11 , G-12
DDN	NVIDIA와 추론 비용 절감 협업(3/17)	G-13
Google Cloud	GKE Inference Gateway + Dynamo 통합	G-14
CoreWeave	SkyPilot 백엔드 지원, HGX B300 GA 유지	G-15
Cisco	Secure AI Factory with NVIDIA(GTC 2026)	G-16

시장 시그널

시장 전망

- Jensen Huang: 2027년까지 \$1T 수주 전망 — 추론 인프라 투자 폭발 신호 G-12
- GTC 2026 "Inflection of Inference" — 추론이 AI 컴퓨트 2/3 차지 G-12

파트너십 & 제휴

- DDN-NVIDIA 추론 비용 최적화(3/17) G-13
- Cisco Secure AI Factory with NVIDIA(GTC 2026) G-16

도입 사례

- Dynamo 1.0: Cursor, Perplexity, PayPal, Pinterest, ByteDance, Meituan 등 프로덕션 G-11
- Akamai: AI Grid 4,400 에지 로케이션 배포 G-17

시장 수요

컨퍼런스 영상에서 수요 시그널을 확인하지 못함.

전략적 시사점

- 1. 추론 인프라 투자 시점 — 학습→추론 전환은 구조적. Dynamo, Vera Rubin 기반 추론 전용 최적화 우선순위 검토.
- 2. 오픈소스 Dynamo 활용 — Apache 2.0으로 벤더 종속 없이 추론 파이프라인 구축 가능.
- 3. 이중 가속기 전략 — 프리필/디코드 분리로 이중 칩(Vera Rubin + Groq 3) 활용이 최적화 패턴.

On-Device sLM —  주목

상세 리서치: [2026-03-24_research-ondevice-slm.md](#)

이전 대비 변화

- 전주: Gemma 3n GA + SmoLLM3-3B SOTA 안정화, 신규 릴리스 없음
- 금주: OpenAI GPT-5.4 mini+nano 출시(3/17), sLM-First 아키텍처 비용 60-70% 절감 패턴 확산
- 변화 방향: 오픈소스 sLM 안정화 위에 **상용 소형 모델 등장** → 엔터프라이즈 예지 도입 가속

기술 동향

- 1. OpenAI GPT-5.4 mini + nano 출시(3/17) — **상용 소형 모델 본격 진입.**
GPT-5 mini 대비 코딩·추론·에이전틱 전면 향상, 2x+ 빠른 실행. tool search 네이티브 지원. nano는 모바일·IoT 타깃. G-18
- 2. sLM (Small Language Model)-First, LLM-Backup 아키텍처 **엔터프라이즈 표준화.**
일상 요청 80%를 로컬 sLM, 복잡한 20%만 클라우드 LLM으로 라우팅. AI 컴퓨트 비용 60-70% 절감. Phi-4(3.8B), Gemma 3(270M~), Qwen3-8B 주요 선택지. G-19
- 3. Google AI Edge RAG — **온디바이스 RAG 공식 지원.**
파인튜닝 없이 대량 데이터에서 관련 정보를 sLM에 제공. Android 우선, 멀티플랫폼 확장 예정. G-20
- 4. NPU 세대교체 — **2026형 칩셋 sLM 전용 최적화.**
Qualcomm X2, Samsung Exynos 2600, MediaTek 신규 NPU. Gemma 3 4B가 Apple Silicon에서 4비트 양자화로 인터랙티브 속도. TI NPU MCU는 90x 지연 감소, 120x 에너지 절감 시연. G-21

플레이어 동향

기업	동향	출처
OpenAI	GPT-5.4 mini+nano(3/17), tool search 네이티브, 모바일·IoT 타깃	G-18
Google	Gemma 3n 멀티모달 GA, AI Edge RAG, LiteRT HuggingFace	G-20
TI	NPU 내장 MCU(3/10) — 초저전력 예지 AI	G-21

시장 시그널

시장 전망

- Gartner: 2027년까지 소형 과업별 AI 모델 사용이 범용 LLM 대비 3배 G-19

도입 사례

- sLM-First 아키텍처: 일상 80% 로컬, 비용 60-70% 절감 G-19

시장 수요

고객 페인포인트

- 모델 크기 vs 성능 트레이드오프(4GB RAM 제약)
- MoE (Mixture of Experts) 모델의 전문가 로딩 병목("컴퓨터 빠르나 메모리 셔플링이 병목")

시장 니즈

- 토큰 sLM 배포 + 에지 최적화 + 매니지드 서비스 결합 제품
- 프라이버시 보존 온디바이스 AI(통신·금융·의료 규제 산업)

전략적 시사점

1. GPT-5.4 mini/nano 경쟁 심화 — 상용 소형 모델이 오픈소스 sLM과 성능·편의성 경쟁 시작.
2. sLM-First 아키텍처 도입 — 80/20 티어드 전략으로 비용 60-70% 절감. 자사 AI 서비스 적용 검토.
3. 온디바이스 RAG 파이프라인 — 파인튜닝 없이 도메인 데이터 주입하는 패턴 표준화.

Edge AI — 주목

상세 리서치: [2026-03-24_research-edge-ai.md](https://www.research-edge-ai.md)

이전 대비 변화

- 전주: GTC 2026 "Inflection of Inference", ExecuTorch 1.0 프로덕션 확산
- 금주: AT&T-Cisco-NVIDIA AI Grid 상용 배포(3/17-19), Akamai 4,400 에지 배포, TI NPU MCU(3/10)
- 변화 방향: 에지 AI PoC → **대규모 프로덕션 배포** 전환. 통신사·CDN이 에지 추론 인프라 상용화 주도

기술 동향

1. AT&T-Cisco-NVIDIA AI Grid — 네트워크 주도 에지 AI 상용 배포(3/17-19).
AT&T 전용 IoT 코어 + Cisco Mobility Services Platform + NVIDIA 가속 컴퓨트. 로컬 트래픽 브레이크아웃, 결정적 성능, 제로트 러스트 보안. Dallas Discovery District 라이브 + 루이지애나 산업 파일럿. G-22
2. Akamai — NVIDIA AI Grid 4,400 에지 로케이션 배포(최초 대규모).
CDN 인프라의 AI 추론 플랫폼 전환. 에지 추론의 클라우드 의존 탈피 신호. G-17
3. TI NPU 내장 MCU — 초저전력 에지 AI 하드웨어(3/10).
TinyEngine NPU로 유사 MCU 대비 지연 90x 감소, 추론당 에너지 120x 절감. 산업 자동화·스마트 빌딩 타깃. G-21
4. Cisco Secure AI Factory — 보안 중심 에지 AI 아키텍처(GTC 2026).
에지~데이터센터 보안·거버넌스·오케스트레이션 통합 관리. G-16

플레이어 동향

기업	동향	출처
AT&T	Cisco-NVIDIA AI Grid 상용 배포(3/17), Dallas 라이브 + 산업 파일럿	G-22
Akamai	AI Grid 4,400 에지 로케이션 — 최초 대규모 에지 추론	G-17
Cisco	Secure AI Factory + AI Grid 에지 보안 아키텍처	G-16
TI	NPU MCU(3/10), 90x 지연 감소	G-21

시장 시그널

파트너십 & 제휴

- AT&T-Cisco-NVIDIA 에지 AI Grid(3/17) — 통신사 네트워크 자산 활용 에지 추론 G-22
- Akamai-NVIDIA AI Grid 글로벌 배포 — CDN→에지 AI 인프라 전환 G-17

시장 전망

- 에지 AI 시장 2030년까지 \$1,232억(CAGR 20.3%) G-23

도입 사례

- AT&T Discovery District 라이브 — 비디오 보안, 교통, 제조, 산업 자동화 G-22

시장 수요

고객 페인포인트

- 에지 AI 프로젝트 70%가 PoC에서 정체 — 운영 복잡성·파편화가 핵심 원인
- 이종 OS·하드웨어·불안정한 네트워크에서의 일관된 배포·관리 어려움

시장 니즈

- 턴키 에지 AI 배포 솔루션(AT&T-Cisco-NVIDIA AI Grid가 정확히 충족)
- 에지 보안·거버넌스 통합 플랫폼

전략적 시사점

1. **통신사 에지 자산 활용** — AT&T 모델은 통신사 네트워크 인프라를 에지 추론 플랫폼으로 전환하는 선례. 자사 5G 코어·에지 인프라 활용 가능성 검토.
2. **CDN→에지 AI 진화** — Akamai 4,400 배포는 CDN 사업자가 에지 AI 핵심 플레이어로 부상.
3. **PoC→프로덕션 전환 지원** — 70% PoC 정체를 해결하는 턴키 솔루션이 차별화 포인트.

경쟁사 동향 (SKT / KT)

SKT			
항목	내용	관련 L3	출처
SKT-에릭슨 MoU(3/19)	AI-RAN·5G 수익화·자율 네트워크·제로트러스트·6G 표준화 5개 축, 2031년까지	5g-6g-ai-ran	E-01
AI 메가 데이터센터 계획	전국 1GW+ 규모 AI 데이터센터 구축, 아시아 최대 AI 허브 목표	gpu-orchestration	E-02
A. AI 에이전트 서비스	구독 기반 AI 수익 모델 강화, B2B AI·클라우드 솔루션 확대	agent-orchestration	E-02

KT			
항목	내용	관련 L3	출처
에이전트 빌더 (MWC26)	노코드 드래그앤드롭 AI 에이전트 제작 플랫폼, RAG·AI 핵심 기능 모듈화, 금융·제조·공공 템플릿	agent-orchestration	E-03
K GPUaaS	월 구독형 GPU 서비스 + 온프레미스 AI GPU Managed	gpu-orchestration	E-03

규제 & 거버넌스

시행 임박 / 카운트다운

규제	시행일	D-day
한국 AI 기본법 (인공지능 발전과 신뢰 기반 조성 등에 관한 기본법)	2026-01-22	시행 중 (계도기간)
EU AI Act — 고위험 AI 시스템 (Annex III)	2026-08-02	D-131
EU AI Act — 제품 안전 AI (Annex I)	2027-08-02	D-496

신규 발의 & 가이드라인

- 미국 백악관 AI 정책 프레임워크(3/20): 7대 권고안 발표. 새로운 연방 규제 기관 신설 반대, 기존 규제기관을 통한 "부문별(sector-specific)" 접근 권장. AI 에이전트 자율 행위에 대한 책임 소재는 미언급. G-24
- TRUMP AMERICA AI Act 법안(3/18): 연방 AI 조달 보호, Section 230 책임 보호 수정 등 제안. AI 에이전트에 대한 직접적 규제 조항은 미포함. G-25
- 한국 AI 기본법 시행(1/22): 고영향 AI 사업자 특별 책무, 투명성·안전성 확보 의무 적용 시작. 에이전트의 자율적 판단 오류 시 책임 소재(개발사·운영사·사용자)가 업계 핵심 쟁점. 과기정통부가 최소 1년 규제 유예 계도기간 운영 중. G-26

시사점

- EU AI Act 고위험 AI 시스템 규정 D-131: 에이전틱 AI가 고위험으로 분류될 경우 적합성 평가·기술 문서·CE 마킹 필요. 자사 에이전트 서비스의 EU 고위험 분류 여부 사전 검토 필요.
- 한국 AI 기본법: 에이전트 자율 행위의 법적 책임 해석이 미확정 — 서비스 설계 시 인간 감독(human-in-the-loop) 메커니즘 내장 권장.

종합 시사점 및 후속 조치

이번 주 핵심 전환

- 1. 에이전트 프레임워크 4강 동시 프로덕션 업데이트
 - OpenAI(SDK 0.13), Anthropic(Channels), Google(ADK A2A), Microsoft(Foundry GA)가 같은 주에 발표. MCP + A2A 듀얼 스택이 사실상 표준. 자사 에이전트 설계에 두 프로토콜 대응 필수.
- 2. 학습→추론 구조적 전환 가속
 - NVIDIA Dynamo 1.0 GA + Vera Rubin 플랫폼이 "AI 팩토리 OS" + 차세대 하드웨어를 동시 제시. 추론 전용 인프라 투자 시점 도래.
- 3. 에지 AI 대규모 프로덕션 진입
 - AT&T AI Grid, Akamai 4,400 로케이션이 에지 추론의 PoC→상용 전환 확인. 통신사 에지 자산 활용 전략 수립 시급.
- 4. 상용 소형 모델 경쟁 시작
 - GPT-5.4 mini/nano가 오픈소스 sLM과 직접 경쟁. sLM-First 아키텍처(80% 로컬, 비용 60-70% 절감)가 엔터프라이즈 표준으로 부상.

후속 조치 권장

우선순위	조치	관련 L3
●	MCP + A2A 듀얼 프로토콜 대응 전략 수립	agent-orchestration
●	NVIDIA Dynamo 1.0 기반 추론 인프라 PoC 검토	gpu-orchestration
●	자사 5G 에지 인프라의 AI 추론 플랫폼 활용 가능성 분석	edge-ai
●	sLM-First 티어드 아키텍처 파일럿 설계	ondevice-slm
●	EU AI Act 고위험 AI 에이전트 분류 사전 검토	전체

References

#	출처	URL	유형	날짜	신뢰도
G-01	OpenAI Agents SDK 0.13 Releases	링크	G	2026-03-23	high
G-02	VentureBeat — Claude Code Channels	링크	G	2026-03-20	high
G-03	Google Cloud Blog — A2A ADK 업그레이드	링크	E	2026-03	high
G-04	MS Foundry Blog — Foundry Agent Service GA	링크	E	2026-03-16	high
G-05	Visual Studio Magazine — VS Code 1.112	링크	G	2026-03-18	high
G-06	Fortune — Interloom \$16.5M VC	링크	G	2026-03-23	high
G-07	NxCode — CrewAI vs LangChain 2026	링크	G	2026-03	medium
G-08	Tracxn — Agentic AI Market 2026	링크	G	2026-03	medium
G-09	Enterprise AI Agent Adoption March 2026	링크	G	2026-03-16	medium
G-10	Salesforce — Multi-Agent Adoption Report	링크	E	2026-03	high
G-11	NVIDIA Newsroom — Dynamo 1.0 GA	링크	E	2026-03-16	high
G-12	CNBC — NVIDIA GTC 2026 Vera Rubin \$1T	링크	G	2026-03-16	high
G-13	Blocks & Files — DDN-NVIDIA 추론 비용 절감	링크	G	2026-03-17	high
G-14	Google Cloud Blog — GTC 2026 AI 인프라	링크	E	2026-03-20	high
G-15	CoreWeave Blog — SkyPilot 지원	링크	E	2026-03	high
G-16	Cisco Newsroom — Secure AI Factory with NVIDIA	링크	E	2026-03	high
G-17	DCD — Akamai AI Grid 4,400 로케이션	링크	G	2026-03	high
G-18	9to5Mac — OpenAI GPT-5.4 mini/nano	링크	G	2026-03-17	high
G-19	Iterathon — sLM Enterprise 2026 가이드	링크	G	2026-03	medium
G-20	Google Developers Blog — AI Edge sLM + RAG	링크	E	2026-03	high
G-21	TI Newsroom — 에지 AI MCU	링크	E	2026-03-10	high
G-22	AT&T — Cisco-NVIDIA AI Grid	링크	E	2026-03-17	high
G-23	SiliconANGLE — Edge AI 번곡점	링크	G	2026-03-20	high
G-24	Nextgov — 백악관 AI 정책 프레임워크	링크	G	2026-03-20	high
G-25	Fox Rothschild — TRUMP AMERICA AI Act	링크	G	2026-03-18	medium
G-26	피카부랩스 — AI 기본법 완전 정리	링크	G	2026-01	medium
E-01	Ericsson — SKT-에릭슨 MoU	링크	E	2026-03-19	high
E-02	WithNews — 통신사 AI 인프라 투자	링크	G	2026-03	medium
E-03	AI Times — KT 에이전트 빌더	링크	G	2026-03-04	high
P-01	MAS-Orchestra: RL 기반 MAS 오케스트레이션	링크	P	2026-03	medium