

주간 기술 동향: Agentic AI (2026-W15)

2026-04-06

Executive Summary

이번 주 핵심: Microsoft Agent Framework 1.0 GA(General Availability)(4/3)를 기점으로 주요 에이전트 오케스트레이션 프레임워크의 프로덕션 진입이 완료되었고, Embedded World 2026 후속으로 ASUS UGen300(40 TOPS/2.5W), TI \$1 AI MCU(Microcontroller Unit) 등 엣지 AI 가속기가 PoC(Proof of Concept)에서 양산 가능 제품으로 전환 가속 중이다.

Layer 2	세부기술	신호	핵심 내용
Trusted Multi-Agent Orchestration	Intelligent Agent Orchestration	●	[제품출시] MS Agent Framework 1.0 GA(4/3), Copilot Studio 멀티에이전트 GA · [생태계] MCP Dev Summit 종료, SDK v2 로드맵 공개 · [제품출시] Google Gemma 4 온디바이스 에이전트
	Agent Oriented Orchestration	●	Plan-and-Act 하이브리드 패턴 안정 유지
Hybrid AI Infra	Edge AI	●	[제품출시] ASUS UGen300(Hailo-10H, 40 TOPS, 2.5W) · [기술돌파] Nordic Axon NPU(Neural Processing Unit) 15x 추론 향상 · [제품출시] TI \$1 이하 AI MCU 양산
	On-Device sLM	●	FunctionGemma/Qwen 3.5/Gemma 3 정착 유지, sLM-First 비용 절감 지속
	5G SA/6G (AI-RAN/SRv6)	●	MWC·P.I. Works-TELUS 후속 정착, NVIDIA Aerial 오픈소스
	실시간 화자분할(2인)	●	Voxtral sub-200ms, AssemblyAI Universal-3-Pro 안정 유지
Model & Delta Foundry	GPU Orchestration	●	SkyPilot Agent Skills 에코시스템 성숙, 추가 발표 없음
	FeedbackOps: Meta-prompt Engineering	●	DSPy MIPROv2 안정, 신규 릴리스 없음
	EvaluationOps: KMS 성능평가	●	RAGAS 에이전트 워크플로우 평가 확장, 도구 생태계 성숙
	데이터-학습-배포 파이프라인	●	AgentOps 개념 정착, 보안/거버넌스 프레임워크 공식화
Self Evolving Architecture	Agentic Context Engineering	●	ACE(Agentic Context Engineering) ICLR 2026 생태계 성숙 지속
의도 파악 기술	Adaptive RAG	●	Router Pattern 표준 유지, Hybrid RAG 프로덕션 베이스라인

신호 : ● 긴급 — 경쟁사 출시, 규제 변경, 기술 돌파 | ● 주목 — 주요 발표·논문·표준 변화 감지 | ● 평온 — 유의미 변화 없음 **태그**
: [기술돌파] [제품출시] [경쟁사] [규제] [투자] [논문] [생태계]

목차

Executive Summary

Quick 요약 (변화 미미)

Agent Oriented Orchestration

On-Device sLM

5G SA/6G (AI-RAN/SRv6)

Speaker Diarization

GPU Orchestration

FeedbackOps (Meta-prompt Engineering)

EvaluationOps (KMS 성능평가)

MLOps Pipeline

Agentic Context Engineering

Adaptive RAG

Deep 심층 분석

Intelligent Agent Orchestration —  주목

Edge AI —  주목

경쟁사 동향 (SKT / KT)

SKT

KT

시사점

규제 & 거버넌스

시행 임박 / 카운트다운

신규 발의 & 가이드라인

시사점

종합 시사점 및 후속 조치

기술 간 교차 시사점

후속 조치 제안

References

Quick 요약 (변화 미미)

Agent Oriented Orchestration

- Plan-and-Act 하이브리드 패턴(고추론 DAG(Directed Acyclic Graph) 분해 → 경량 실행 → 재계획)이 엔터프라이즈 배포 주류 유지. LATS(Language Agent Tree Search) 참조 증가. 이번 주 추가 변화 없음.

On-Device sLM

- FunctionGemma 270M, Qwen 3.5 4B, Gemma 3 1B 기존 정착 유지. sLM-First 아키텍처 60-70% 비용 절감 패턴 지속. Google Gemma 4 E2B(1.5GB 미만)가 에이전트 특화 온디바이스 모델로 출시되었으나 Edge AI 섹션에서 별도 분석.

5G SA/6G (AI-RAN/SRv6)

- MWC 2026 후속 정착 단계. NVIDIA Aerial 오픈소스 6G AI-native 스택, P.I. Works-TELUS AI-RAN 자동화 파트너십(4/1) 후속. 3GPP 6G 스펙 2029년 목표 유지. CSP(Communication Service Provider) 65%가 AI 팩토리 배포/시범 중.

Speaker Diarization

- Mistral Voxtral Realtime sub-200ms, AssemblyAI Universal-3-Pro 30% 노이즈 개선 안정 유지. Gladia Solaria-1 103ms 다국어 지원. 돌파구 수준 변화 없음.

GPU Orchestration

- KubeCon Europe 후속 정착. SkyPilot Agent Skills(GPU 접근·잡 관리), CoreWeave 통합(7 GB/s), Shopify 프로덕션 채택 등 에코시스템 성숙. 이번 주 추가 발표 없음.

FeedbackOps (Meta-prompt Engineering)

- DSPy MIPROv2 옵티마이저 안정 운영 지속. GEPA(Genetic-Pareto Reflective Optimizer), BetterTogether 등 학술 연구 진행 중. 이번 주 신규 릴리스 없음.

EvaluationOps (KMS 성능평가)

- RAGAS v0.2+ 에이전트 워크플로우 평가 확장 지속. LLM-as-judge 80-90% 인간 일치율 유지. MIRAGE-Bench 다국어 RAG(Retrieval-Augmented Generation) 평가 등장. 이번 주 돌파구 없음.

MLOps Pipeline

- MLOps→LLMOps→AgentOps 전환 가속 중. AgentOps(장기 실행·다단계 에이전트 관리) 개념이 정착. DevSecMLOps(보안 통합 파이프라인) 프레임워크 공식화 진행. 구체적 신규 제품 출시 없음.

Agentic Context Engineering

- ACE(ICLR 2026) 프레임워크: AppWorld +17.1%, MCE(Meta Context Engineering) 논문 5.6-53.8% 개선 보고 등 생태계 성숙 지속. GitHub Agent-Skills-for-Context-Engineering 툴킷 등장. 프로덕션 적용 사례는 아직 미확인.

Adaptive RAG

- Router Pattern이 2026 표준으로 정착. Hybrid RAG(밀집+희소 검색 조합) 프로덕션 베이스라인. 프로덕션 LLM 앱 85%가 RAG 사용(2024년 30%에서 상승). 이번 주 변화 없음.

Intelligent Agent Orchestration — 주목

상세 리서치: [2026-04-06_research-agent-orchestration.md](#)

이전 대비 변화

- 전주: MCP Dev Summit 개막(4/2-3 NYC), AG-UI(Agent-User Interaction Protocol) 3대 프로토콜 스택 형성, MS Agent Framework .NET RC5 출하
- 금주: Microsoft Agent Framework 1.0 GA(4/3), Google Gemma 4 온디바이스 에이전트(4/2), MCP SDK v2 로드맵 최초 공개, Copilot Studio 멀티에이전트 GA(4/1)
- 변화 방향: RC → GA 전환 완료 국면 — 에이전트 프레임워크 프로덕션 진입 확정. 온디바이스 에이전트·멀티모델 라우팅이 새 경쟁 축으로 부상.

기술 동향

- Microsoft Agent Framework 1.0 GA(4/3) — 멀티에이전트 오케스트레이션 프레임워크 정식 출하.**
Python·.NET 양쪽 SDK가 동시에 1.0 정식 버전으로 전환. AutoGen과 Semantic Kernel의 통합 결과물로, 단일 에이전트 추상화·미들웨어·혹·플러그인 메모리·그래프 기반 워크플로우·멀티에이전트 패턴(순차·동시·핸드오프·그룹 채팅·Magentic-One)이 안정 API로 확정. MCP 지원 포함, A2A(Agent-to-Agent)는 "coming soon" G-01.
- MCP Dev Summit 종료(4/2-3, NYC) — MCP SDK v2 로드맵 최초 공개.**
AAIF(Agentic AI Foundation) 주관 95개 세션. Anthropic Max Isbey가 Python SDK v2 로드맵을 공식화, 인증 아키텍처 (`mcp.server.auth`) 재설계 가능성 언급. OAuth 2.1 명세 저자 Aaron Parecki와 Anthropic Paul Carleton이 "에이전트를 위한 SSO(Single Sign-On)" 세션 공동 진행 G-02, G-03.
- Google Gemma 4 출시(4/2) — 온디바이스 에이전트 특화 오픈 모델.**
Apache 2.0 라이선스, E2B(1.5GB 미만)·E4B 버전. 단단계 계획·자율 행동·오프라인 코드 생성·멀티모달 처리 특화. Agent Skills API로 외부 지식·다른 모델 통합. 128K 컨텍스트, 140+ 언어. GKE(Google Kubernetes Engine) Agent Sandbox 초당 300 샌드박스 보안 격리 G-04, G-05.
- Copilot Studio 멀티에이전트 GA(4/1) — A2A 지원, 멀티벤더 모델 개방.**
A2A 프로토콜로 외부 에이전트 직접 통신·위임. Microsoft Fabric 연동 엔터프라이즈 데이터 추론. Claude Opus 4.6·Sonnet 4.5, Grok 4.1, GPT-5.3/5.4 등 다중 공급자 모델 확장 G-06.
- LangGraph 1.1.5~1.1.6(4/3) — 실행 정보·원격 빌드 안정화.**
4월 첫 주 두 개 패치 연속 출하. W16의 타입 안전 스트리밍·Pydantic 강제 변환 기능 후속 안정화 G-07.
- IBM watsonx Orchestrate 보이스 확장(4/1) — Deepgram·ElevenLabs 파트너십.**
음성 인식(Deepgram) + TTS(Text-to-Speech)(ElevenLabs) 통합으로 브랜드 음성 에이전트·다국어 더빙·커스텀 음성 클로닝 지원. Elsewedy Electric 엔터프라이즈 에이전트 AI 전략 협력 발표 G-08, E-01.
- AWS AgentCore Policy GA — 에이전트-도구 거버넌스 레이어.**
에이전트-도구 상호작용에 대한 세분화된 중앙 제어를 에이전트 코드 외부에서 적용. Stateful MCP 서버 기능(elicitation, sampling, progress notifications) 추가 G-10, G-11.
- 멀티모델 라우팅 — 에이전트 오케스트레이션 필수 역량으로 부상.**

각 서브에이전트·태스크 유형에 최적 모델을 동적 배정하는 아키텍처가 "nice-to-have"에서 "must-have"로 격상. 특정 LLM 종속 탈피 설계 필요성 증가 **G-12**.

플레이어 동향

기업	동향	출처
Microsoft	Agent Framework 1.0 GA(4/3): Python·.NET 동시 정식, MCP 지원, A2A "coming soon"; Copilot Studio 멀티에이전트 GA(4/1): A2A·Fabric·다중 모델	G-01 , G-06
Google	Gemma 4(4/2): 온디바이스 에이전트 오픈 모델 E2B/E4B, Apache 2.0; GKE Agent Sandbox 초당 300 샌드박스	G-04 , G-05
LangChain	LangGraph 1.1.5-1.1.6(4/3): CLI 원격 빌드·실행 정보 안정화; 28.5k GitHub 스타	G-07
IBM	watsonx Orchestrate(4/1): Deepgram·ElevenLabs 보이스 파트너십; Elsewedy Electric 전략 협력	G-08 , E-01
AWS	AgentCore Policy GA: 중앙 거버넌스; Stateful MCP 서버 기능 추가	G-10 , G-11
Anthropic	MCP SDK v2 로드맵 공개(Dev Summit); 에이전트용 SSO 세션; Claude Haiku 3 은퇴(4/20) 임박	G-02
OpenAI	SDK 0.13.4 이후 추가 릴리스 미확인; MCP x MCP 키노트(Dev Summit 4/3, Nick Cooper)	G-09 , G-03
CrewAI	1.1.0: 멀티공급자 LLM·Qdrant Vector Search 개선; 이번 주 추가 릴리스 미확인	G-13

시장 시그널

투자 & M&A

- 에이전트 AI 섹터 누적 투자 \$4.4억+, 2024년 피크 \$20.18억; 에이전트 인에이블러(플랫폼·오케스트레이션)가 총 투자의 55%+ 차지 **G-14** [추가확인 필요]

파트너십 & 제휴

- Copilot Studio ↔ A2A: 외부 에이전트 직접 통신·위임 공식 지원 **G-06**
- IBM watsonx ↔ Deepgram·ElevenLabs: 음성 에이전트 인프라 확장 **G-08**
- Gemma 4 ↔ NVIDIA RTX/Spark: 온디바이스 에이전트 AI 가속 **G-05**

시장 전망

- 에이전트 스프롤(Agent Sprawl)이 2026년 엔터프라이즈 AI 거버넌스 최대 과제로 부상 **G-12**
- 멀티모델 라우팅이 에이전트 아키텍처 새 표준 — 특정 LLM 종속 탈피 설계 필요 **G-12**

도입 사례

- Microsoft Ask Microsoft: 멀티에이전트 아키텍처 제품 도메인별 서브에이전트 분산 처리 [원문 미확인] **G-06**
- IBM Elsewedy Electric: watsonx 기반 엔터프라이즈 에이전트 AI 도입 **E-01**

연구 동향

- "Hierarchical Memory Orchestration for Personalized Persistent Agents" (Liu et al., 2026) — 3단계 계층형 메모리로 온디바이스 에이전트 개인화 장기 기억 구현 **P-01**
- "ClinicalAgents: Multi-Agent Orchestration with Dual-Memory" (2026) — MCTS(Monte Carlo Tree Search) 기반 동적 오케스트레이터·이중 메모리 아키텍처 **P-02**

커뮤니티 시그널

- MCP Dev Summit 95개 세션 녹화 공개 — MCP SDK v2 인증 변경에 대한 개발자 대응 논의 시작 **G-02**

- HN "MCPlenor": MCP 멀티플렉서 환경에서 요청당 40-50k 토큰 낭비 문제 — 시맨틱 라우팅으로 500 토큰 수준 오버헤드 절감 시도 C-01

시장 수요 (voice-of-market)

Harrison Chase(LangChain) Interrupt 2025 키노트, Douwe Kiela(Contextual AI) AI Engineer Summit, HN 실무자 쓰레드 기반.

고객 페인포인트

- 프로토타입→프로덕션 신뢰성 격차 — "쉽게 작동하는 것을 만들 수 있지만, 비즈니스에서 레버를 움직일 만큼 신뢰할 수 있게 만들기 어렵다" — Harrison Chase (LangChain) C-02
- MCP 멀티플렉서 토큰 낭비 — 여러 MCP 서버 연결 시 요청당 40-50k 토큰 주입, 200k 컨텍스트의 25% 소진. 실제 사용 토큰은 1-2개 C-01
- 프로덕션 무성 실패 — Prosus 7,949개 에이전트 배포, 성공률 15% C-03

도입 장벽

- 다학제적 전문성 요구 — prompting + engineering + product sense + ML 복합 역량의 "agent engineer" 인재 극히 희소 C-02
- MCP 생태계 품질 파편화 — 서버 구현 품질 편차 극심, 인증 시스템 불안정 C-04
- 파일럿→프로덕션 전환 — 수만~수백만 건 문서, 20,000+ 유스케이스 확장 시 기존 도구 불가 — Douwe Kiela (Contextual AI) C-05

시장 니즈

- 프로덕션급 에이전트 배포 플랫폼 (long-running, bursty, stateful 네이티브)
- 멀티모달 AI 전용 관찰가능성 스택
- 비개발자용 노코드 에이전트 빌더
- MCP 컨텍스트 효율화 (시맨틱 라우팅 기반 멀티플렉서)
- 도메인 특화 RAG 에이전트 ("specialization over AGI")

전략적 시사점

기회

- Agent Framework 1.0 GA = 도입 최적 타이밍 — RC 불안정성 없이 파일럿 시작 가능
- 온디바이스 에이전트: Gemma 4 E2B(1.5GB 미만)로 망 엣지 에이전트 실행 현실화
- MCP SDK v2 인증 표준화 선점: v2 스펙 확정 전 추상화 레이어 설계로 마이그레이션 비용 절감
- 멀티공급자 오케스트레이터: Copilot Studio의 Claude·GPT·Grok 동시 지원이 표준화 — LLM 종속 탈피 설계

위협

- Claude Haiku 3 은퇴(4/20) 2주 남음 — 서브에이전트 파이프라인 즉시 마이그레이션 필요
- A2A 지원 공백: MS Agent Framework 1.0 GA에 A2A 미포함("coming soon") — 크로스런타임 협업 계획 시 주의
- MCP SDK v2 인증 breaking change 리스크: 현재 FastAPI+MCP 인증 코드 동결 권고

Edge AI — 주목

상세 리서치: [2026-04-06_research-edge-ai.md](https://research-edge.ai.md)

이전 대비 변화

- 전주: TI TinyEngine NPU 90x 저지연·120x 에너지 효율 발표, 추론칩 시장 \$50B 전망, 서브 1B 모델 실용화 변곡점
- 금주: ASUS UGen300(Hailo-10H, 40 TOPS(Tera Operations Per Second), 2.5W) 출시(4/1), Nordic Axon NPU 15x 추론 향상, TI \$1 이하 MCU 양산, MediaTek Genio 420 4월 샘플링
- 변화 방향: PoC·발표 → 양산·실구매 가능 제품 전환 가속 — USB 폼팩터 AI 가속기, \$1 이하 AI MCU 등 가격 장벽 붕괴 시작

기술 동향

1. ASUS UGen300 출시(4/1) — USB-C 플러그인 엣지 AI 가속기.

Hailo-10H NPU 탑재, 40 TOPS / 2.5W / 8GB LPDDR4(Low Power Double Data Rate 4). USB 3.1 Gen 2로 Windows·Linux·Android 바로 연결. TensorFlow·PyTorch·ONNX(Open Neural Network Exchange) 지원. Windows 드라이버 5월 중순 예정 [G-15](#).

2. Nordic nRF54LM20B Axon NPU — IoT 추론 속도 15x 향상.

128MHz Axon NPU 내장 SoC(System-on-Chip). TFLite(TensorFlow Lite) 추론 CPU 대비 15x, 경쟁 무선 NPU 대비 7x 성능·8x 효율. Q2 광범위 개발 키트 출시 예정 [G-16](#).

3. Synaptics+Google Coral — 업계 최초 Coral NPU 상용 구현.

Astra SL2610 SoC에 1 TOPS Torq NPU 탑재. Gemma 3 270M 기본 탑재. MLIR(Multi-Level Intermediate Representation) 기반 오픈소스 툴체인으로 PyTorch·TFLite 단일 워크플로 배포 [G-17](#).

4. MediaTek Genio 시리즈 — 3nm~6nm 풀 라인업.

Genio Pro(3nm, 50 TOPS+), Genio 420(6nm, 7.2 TOPS, 4월 샘플링), Genio 360/360P(6~8.5 TOPS). 최대 2B 파라미터 엣지 추론 지원 [G-18](#).

5. TI MSPM0G5187 — \$1 이하 AI MCU 양산.

Arm Cortex-M0+ 80MHz, TinyEngine NPU로 추론 90x 저지연·120x 에너지 절감. 1,000개 기준 \$1 이하 [G-19](#).

6. Ambiq Atomiq SoC — 300mV 초저전압 NPU.

12nm FinFET, Arm Ethos-U85 NPU, 200 GOPS(Giga Operations Per Second). 항상 켜진 오디오·비전·추론 AI 실용화. 양산 (Atomiq110) 2027년 예정 [G-20](#).

7. NPU 벤치마크 — TOPS 지표의 한계 확인.

Apple M4 Max가 낮은 TOPS에도 통합 메모리로 LLM 추론 우위. NPU는 GPU 대비 추론 60% 향상, 전력 40~45% 절감. 메모리 대역폭이 실성능 결정 인자 [G-21](#).

8. LLM 엣지 추론 논문 — 모바일 열 관리가 핵심 제약.

Hailo-10H: 6.9 t/s / 2W 미만 vs RTX 4050: 131.7 t/s / 34.1W. 에너지 효율에서 엣지 NPU 우위, 모바일 열 스로틀링이 병목 (Tummalapalli et al., 2026) [P-03](#).

9. 통신사 AI-RAN + MEC 연동 진전.

SoftBank-Ericsson PoC 완료: 로봇 AI 작업 MEC 동적 오프로드. T-Mobile NVIDIA Blackwell 파일럿 배포. MEC 시장 2031년 \$3.88B(CAGR 30.1%) [G-22](#), [G-23](#).

10. Qualcomm 한국 AI 스타트업 프로그램 참여(4월).

Dragonwing Q-8750(77 TOPS, 11B LLM 온디바이스) 기반 "Challenge AX for All" 프로그램 참여 [G-24](#).

플레이어 동향

기업	동향	출처
ASUS	UGen300 USB AI 가속기(4/1), Hailo-10H 40 TOPS, 2.5W, 8GB LPDDR4	G-15
Hailo	Hailo-10H GA 전환 완료, ASUS·Raspberry Pi 등 다수 OEM(Original Equipment Manufacturer) 채택	G-26
Nordic	nRF54LM20B Axon NPU Q2 광범위 출시, Edge AI Lab 통합 파이프라인	G-16
Synaptics	Google Research와 Coral Dev Board 공동 출시, Gemma 3 270M 기본 탑재	G-17
MediaTek	Genio Pro(50 TOPS+)·420·360/360P 발표, 4월 샘플링 시작	G-18
TI	MSPM0G5187 \$1 이하 AI MCU 즉시 양산 공급, 90x 저지연·120x 효율	G-19
Samsung	Galaxy S26 EdgeFusion(Exynos 2600 2nm NPU) 온디바이스 이미지 생성	G-25
Qualcomm	Dragonwing Q-8750(77 TOPS) 한국 스타트업 프로그램 참여(4월)	G-24
Ericsson	SoftBank와 AI-RAN+MEC PoC 완료, 로봇 AI 동적 오프로드 시연	G-22

시장 시그널

시장 전망

- 엣지 AI 칩 시장: 2025년 \$3.67B → 2031년 \$11.54B(CAGR(Compound Annual Growth Rate) 21%) G-27
- 장기: 2036년 \$80B+ — 자동차·AI 스마트폰·AI PC·휴머노이드 로봇·AI 센서 견인 G-28
- MEC 시장: 2026년 \$1.04B → 2031년 \$3.88B(CAGR 30.1%) G-23

도입 사례

- ASUS UGen300: 플러그인 방식 엣지 AI, 100개+ 사전 학습 모델 번들 예정 G-15
- TI MCU: \$1 이하로 가전·산업 자동화 AI 탑재 비용 장벽 제거 G-19
- SoftBank+Ericsson: MEC 플랫폼에 로봇 AI 작업 동적 오프로드 G-22

연구 동향

- "LLM Inference at the Edge" (Tummalapalli et al., 2026) — 4개 플랫폼 벤치마크, 열 관리가 핵심 제약 P-03
- "eIQ Neutron" (NXP 외, 2025) — 컴파일러-NPU 통합 설계로 동일 TOPS 대비 1.8x(최대 4x) 추론 향상 P-04

커뮤니티 시그널

- HN "AI PCs Aren't Good at AI": NPU 소프트웨어 생태계 미성숙, 메모리 대역폭 병목 활발 논의 C-06
- Nordic DevZone Axon NPU 성능 스펙 문의 급증 — 샘플링 단계 개발자 수요 반영 G-29

시장 수요 (voice-of-market)

Embedded World 2026 키노트(Microchip COO Rich Simoncic), GTC 2026 리캡, HN 개발자 커뮤니티 기반.

고객 페인포인트

- NPU 소프트웨어 생태계 미성숙 — 하드웨어 출시 시 runtime 미동시 제공, 개발자가 직접 inference 코드 작성 강요 — HN 커뮤니티 C-06
- NPU-LLM 구조적 불일치 — NPU는 CNN(Convolutional Neural Network) 스타일 weight 스트리밍에 강하나, LLM 워크로드에서 메모리 대역폭 병목 심화 — HN 커뮤니티 C-06
- 분산 엣지 배포 관리 복잡성 — 수백~수천 노드에 "cloud-like simplicity" 부재, 70% Industry 4.0 프로젝트 파일럿 단계 중단 — GTC 2026 (Zededa)

도입 장벽

- NPU 벤더별 프로그래밍 모델 파편화 — 통일 프로그래밍 모델 없음, 여러 코드 경로 유지 비용 C-06
- 모델 변환 품질 불안정 — 커스텀 PyTorch→On-device 변환 시 출력 불일치 빈발 C-07
- 최신 모델 아키텍처 공식 지원 부재 — SAM2, Whisper, Kokoro 등 TFLite/LiteRT 포팅 없음 C-07

시장 니즈

- "Build Once, Run Anywhere" 크로스플랫폼 소프트웨어 스택
- 분산 엣지 노드 중앙 통합 관리 플랫폼
- 저전력·컴팩트 추론 하드웨어 (ASUS UGen300이 이 니즈 정면 대응)
- 개방형 프레임워크 및 벤더 중립 툴체인

전략적 시사점

기회

- 가격 장벽 붕괴: TI \$1 이하 AI MCU, ASUS USB 가속기로 엣지 AI 하드웨어 대중화 시점 2026 H1으로 앞당겨짐
- 멀티벤더 에코시스템 성숙: Hailo+Nordic+Synaptics/Google+MediaTek 생태계 표준화 — 벤더 종속 없이 솔루션 설계 가능
- 통신 인프라 엣지 AI화: AI-RAN+MEC PoC 완료로 네트워크 엣지를 AI 추론 플랫폼으로 운영하는 모델 가시화
- 소형·저전력 모델 실용화: Gemma 3 270M, Qwen 2.5 1.5B(4bit) 등 상용 NPU에서 실시간 추론 가능

위험

- TOPS 지표 불일치: 스펙만으로 판단 시 성능 미달 위험 — 벤치마크 기반 검증 필수
- 모바일 열 제약: 지속 부하 시 열 스로틀링 → 제품 SLA(Service Level Agreement)는 최대가 아닌 지속 성능 기준 적용
- NPU 툴체인 파편화: TI CCStudio, Nordic nRF Connect, Hailo SDK, MediaTek NeuroPilot 난립
- Windows 드라이버 지연: ASUS UGen300 Windows 드라이버 5월 중순 → 엔터프라이즈 타임라인 조정 필요

경쟁사 동향 (SKT / KT)

이번 주 해당 도메인과 관련된 SKT·KT의 주요 움직임.

SKT

이번 주(3/30~4/6) 해당 도메인 관련 SKT 신규 뉴스 없음. 기존 동향 유지:

- 1인 1 AI 에이전트 전환(3/16), SK AX Agent Builder Platform, 에이닷 조직 전면 배치 등 W16 보도 지속.

KT

이번 주(3/30~4/6) 해당 도메인 관련 KT 신규 뉴스 없음. 기존 동향 유지:

- 노코드 에이전트 빌더(MWC 3/4), K 인텔리전스 스튜디오, 산업별 AI 템플릿 등 W16 보도 지속.

시사점

- 양사 모두 MWC 발표(3월 초) 이후 신규 뉴스 없이 내부 실행 단계로 전환한 것으로 추정. 글로벌 생태계가 GA 전환(MS Agent Framework, Copilot Studio)으로 빠르게 움직이는 반면, 양사의 프로토콜 전략(MCP/A2A/AG-UI 대응)은 여전히 미공개 상태.

규제 & 거버넌스

해당 도메인에 영향을 미치는 국내외 규제·표준·가이드라인 동향.

시행 임박 / 카운트다운

규제	시행일	D-day
한국 AI 기본법 (인공지능 발전과 신뢰 기반 조성 등에 관한 기본법)	2026-01-22	시행 중
EU AI Act Article 6-49 (고위험 AI 시스템 전면 적용)	2026-08-02	D-118
EU AI Act Article 50 (합성 콘텐츠 투명성)	2026-08-02	D-118
Colorado AI Act (고위험 AI 공개 요건) G-33	2026-06-01	D-56

신규 발의 & 가이드라인

- **NIST AI Agent Standards Initiative 퍼블릭 코멘트 마감(4/2):** 3대 축 — 산업 주도 표준, 오픈소스 프로토콜, 보안·ID 연구. 4월부터 섹터별 리스닝 세션 시작. 에이전트 상호운용성·보안을 위한 미국 최초 연방 프레임워크 G-30
- **NIST NCCoE — AI Agent Identity & Authorization 콘셉트 페이퍼(2/5 발행):** OAuth 2.0 확장, SP 800-207(Zero Trust), SP 800-63-4(디지털 ID) 기반 에이전트 인가·검증 체계 제안 G-30
- **McKinsey AI Agent 거버넌스 로드맵(3월):** 6단계 — 에이전트 ID·범위 정의 → 인간 감독 → 최소 권한 접근 → 모니터링·감사 → 멀티에이전트 거버넌스 → 라이프사이클 관리 G-31
- **CFPB(Consumer Financial Protection Bureau)·SEC(Securities and Exchange Commission) 규제 공백:** Regulation E(소비자 결제)에 AI 에이전트 인가 분쟁 조항 없음. SOX Section 302(내부 통제)에 AI 모델 파라미터 감사 추적 미포함 G-32

시사점

- EU AI Act 고위험 전면 적용까지 D-118. 에이전트 오케스트레이션이 "고위험 AI"로 분류될 경우 리스크 관리·투명성·인간 감독 의무 발생
- NIST가 4/2 코멘트 마감 후 섹터별 리스닝 세션을 시작하면서 미국도 에이전트 전용 규제 프레임워크 구축 가속
- Colorado AI Act(6/1 시행, D-56)이 신규 카운트다운 항목으로 추가 — 고위험 AI 공개 요건이 에이전트 배포에 영향

종합 시사점 및 후속 조치

기술 간 교차 시사점

1. 에이전트 프레임워크 GA 완료 = 프로덕션 진입 시점

: MS Agent Framework 1.0(4/3), Copilot Studio 멀티에이전트(4/1), AWS AgentCore Policy(GA) — 주요 3사가 같은 주에 GA 전환을 완료. 파일럿 시작 시 RC 불안정성 리스크가 해소된 창(window).

2. 온디바이스 에이전트 + 엣지 NPU 수렴

: Google Gemma 4 E2B(1.5GB 미만 에이전트 모델)와 ASUS UGen300(40 TOPS USB 가속기)의 동시 출현은 클라우드 의존 없는 엣지 에이전트 실행 시나리오를 현실화. 통신사 MEC 플랫폼에서 에이전트 호스팅 가능성 검토 가치.

3. 거버넌스 레이어 정착

: AWS AgentCore Policy GA + NIST AI Agent Standards Initiative + McKinsey 6단계 거버넌스 로드맵이 같은 시기에 수렴. "에이전트 배포 전 거버넌스 필수"라는 업계 합의 형성.

후속 조치 제안

- ⚠️ **Claude Haiku 3 은퇴(4/20) 2주 남음** — 서브에이전트 파이프라인 즉시 마이그레이션 (`claude-haiku-4-5-20251001`)
- 🟡 agent-orchestration 지속 모니터링: MS Agent Framework GA 후속·MCP SDK v2 진행 상황 추적
- 🟡 edge-ai 지속 모니터링: ASUS UGen300 Windows 드라이버(5월)·MediaTek Genio 420 샘플링 후속
- 📁 Obsidian 동기화: `/obsidian-bridge` 실행
- 📅 다음 도메인: `/weekly-monitor voice-ai`

References

#	출처	URL	유형	날짜	신뢰도
G-01	Microsoft DevBlogs — Agent Framework Version 1.0	링크	release	2026-04-03	[A]
G-02	DEV Community — MCP Dev Summit 2026: What Python Developers Should Pay Attention To	링크	blog	2026-04-02	[B]
G-03	Linux Foundation — MCP Dev Summit Schedule	링크	event	2026-04-02	[A]
G-04	Google Developers Blog — Gemma 4 Agentic Skills at the Edge	링크	blog	2026-04-02	[A]
G-05	NVIDIA Blog — RTX to Spark: Gemma 4 Local Agentic AI	링크	blog	2026-04-02	[B]
G-06	Microsoft Copilot Blog — Multi-agent Orchestration GA	링크	release	2026-04-01	[A]
G-07	GitHub — langchain-ai/langgraph Releases	링크	release	2026-04-03	[A]
G-08	IBM — watsonx Orchestrate Deepgram·ElevenLabs Partnership	링크	release	2026-04-01	[A]
G-09	GitHub — openai/openai-agents-python Releases	링크	release	2026-04-01	[A]
G-10	The New Stack — AWS AgentCore Policy GA	링크	news	2026-04	[B]
G-11	AWS — AgentCore Runtime Stateful MCP	링크	release	2026-03	[A]
G-12	ABNewswire — Multi-Model Routing Must-Have 2026	링크	news	2026-04-03	[B]
G-13	CrewAI Community — Release 1.1.0	링크	release	2025-10	[B]
G-14	New Market Pitch — Agentic AI Funding Trends	링크	report	2026	[B]
G-15	ASUS Pressroom — UGen300 USB AI Accelerator	링크	news	2026-04-01	[A]
G-16	Nordic Semiconductor — nRF54L Series SoC with Axon NPU	링크	news	2026-01	[A]
G-17	Synaptics — Coral Dev Board with Torq NPU	링크	news	2026-03-10	[A]
G-18	MediaTek — Genio Platforms for Robotics, Drones, IoT	링크	news	2026-03-10	[A]
G-19	TI Newsroom — MCU Portfolio with TinyEngine NPU	링크	news	2026-03-10	[A]
G-20	Ambiq — Atomiq Ultra-Low Power NPU SoC	링크	news	2026-01	[A]
G-21	LocalAIMaster — NPU Comparison 2026	링크	blog	2026	[C]
G-22	Ericsson — SoftBank AI-RAN + MEC PoC	링크	news	2026-02-27	[A]
G-23	Fierce Network — T-Mobile NVIDIA Blackwell AI-RAN	링크	news	2026-03	[B]
G-24	IBTimes — Qualcomm Korea AI Startup Program	링크	news	2026-04	[B]
G-25	Android Authority — Galaxy S26 EdgeFusion On-Device AI	링크	news	2026	[B]
G-26	Hailo — Hailo-10H GA	링크	news	2026	[A]
G-27	Mordor Intelligence — Edge AI Chips Market 2031	링크	report	2026	[B]
G-28	GlobeNewswire — Edge AI Chips Forecast 2026-2036	링크	report	2026-03-11	[B]
G-29	Nordic DevZone — Axon NPU Specs Q&A	링크	blog	2026	[B]
G-30	NIST — AI Agent Standards Initiative	링크	policy	2026-02-17	[A]

#	출처	URL	유형	날짜	신뢰도
G-31	McKinsey — AI Agent Governance Roadmap	링크	report	2026-03	[B]
G-32	Data Innovation — Agentic Commerce Regulation Gap	링크	report	2026-03	[B]
G-33	Baker Donelson — 2026 AI Legal Forecast	링크	report	2026	[B]
E-01	IBM — Elsewedy Electric Agentic AI with watsonx	링크	IR/발표	2026-04-01	[A]
P-01	Liu et al. — Hierarchical Memory Orchestration for Persistent Agents	링크	paper	2026-04-02	[A]
P-02	ClinicalAgents: Multi-Agent Orchestration with Dual-Memory	링크	paper	2026-03-27	[A]
P-03	Tummalapalli et al. — LLM Inference at the Edge	링크	paper	2026-03-24	[A]
P-04	NXP et al. — eIQ Neutron: Edge-AI Inference with Integrated NPU	링크	paper	2025	[A]
C-01	HN — MCPlexor: MCP Multiplexer Token Waste	링크	community	2025-12	[C]
C-02	Harrison Chase — LangChain Interrupt 2025 Keynote	링크	community	2025-05	[B]
C-03	MLOps × Prosus — AI Agents in Production Conference	링크	community	2025-11	[B]
C-04	HN — Show HN: mcp-agent (MCP Ecosystem Quality)	링크	community	2025-01	[C]
C-05	Douwe Kiela — RAG Agents in Production (AI Engineer Summit)	링크	community	2025-02	[B]
C-06	HN — AI PCs Aren't Good at AI: CPU Beats NPU	링크	community	2024-10	[C]
C-07	HN — Google AI Edge: On-device AI Deployment	링크	community	2025-06	[C]